ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



NỀN TẢNG LẬP TRÌNH CHO PHÂN TÍCH VÀ TRỰC QUAN DỮ LIỆU
(CO5177)

BÁO CÁO TỔNG HỢP
PHÂN TÍCH BA LOẠI DỮ LIỆU

GVHD: TS. Lê Thành Sách
Nhóm: G1
HVTH: Phan Thị Minh Thơ – 2470112
Nguyễn Thị Thu An – 2470315

TP. Hồ Chí Minh, tháng 11 năm 2026

Mục lục

1 Phân tích dữ liệu dạng bảng **1**
1.1 Bài toán và bộ dữ liệu . . . 1
1.2 Kiểm tra chất lượng dữ liệu . . . 1
1.3 Phân tích khám phá (EDA) . . . 1
1.4 Chuẩn bị dữ liệu . . . 1
1.5 Xây dựng mô hình . . . 2
1.6 Đánh giá trên tập test . . . 2
1.7 Kết luận . . . 2

2 Phân loại phản hồi của sinh viên **3**
2.1 Bài toán và hướng tiếp cận . . . 3
2.2 Bộ dữ liệu . . . 3
2.3 Kiểm tra chất lượng dữ liệu . . . 4
2.4 Phân tích khám phá dữ liệu . . . 5
2.5 Tiền xử lý dữ liệu . . . 7
2.6 Xây dựng mô hình . . . 8
2.6.1 So sánh các bộ phân lớp trên TF-IDF . . . 8
2.6.2 Embedding tiếng Việt có giúp bộ phân lớp tốt nhất không? . . . 9
2.7 Đánh giá trên tập test . . . 9
2.7.1 TF-IDF hay embedding tiếng Việt? . . . 11
2.7.2 Mô hình dựa vào những từ nào? . . . 11
2.7.3 Mô hình sai ở đâu? . . . 12
2.8 Dự đoán phản hồi mới . . . 12
2.9 Kết luận . . . 12

3 Nhận diện món ăn Việt Nam qua ảnh **15**
3.1 Bài toán và hướng tiếp cận . . . 15
3.2 Bộ dữ liệu . . . 15
3.3 Kiểm tra chất lượng dữ liệu . . . 16
3.4 Phân tích khám phá dữ liệu . . . 18
3.5 Tiền xử lý và tăng cường dữ liệu . . . 21

3.6 Xây dựng mô hình 22
3.6.1 ResNet50 làm bộ trích đặc trưng 23
3.6.2 Fine-tune nhẹ ResNet50 23
3.6.3 Baseline: đặc trưng thủ công 24
3.7 Đánh giá trên tập test 24
3.7.1 Những món nào hay bị nhầm với nhau? 27
3.7.2 Mô hình sai ở đâu? 29
3.8 Dự đoán ảnh mới 31
3.9 Kết luận 31

Danh sách hình vẽ

1.1 Chú thích giả: câu nêu kết luận của hình. 1

2.1 Cả hai nhãn đều mất cân bằng: trong train, `neutral` chỉ chiếm 4.0% và chủ đề `lecturer` chiếm 71.5%. Tỉ lệ giữa ba tập chênh nhau tối đa 2.1 điểm phần trăm. 6
2.2 Tỉ lệ và số câu tiêu cực theo chủ đề: `facility` 95.4% (474 câu), `program` 78.0% (1 716 câu), `others` 40.2% (226 câu), `lecturer` 35.6% (2 909 câu). Phản hồi về cơ sở vật chất ít nhưng gần như toàn là phàn nàn, còn giảng viên chiếm 54.6% tổng số câu tiêu cực. 6
2.3 Trung vị độ dài là 12 từ với câu `negative`, 9 với `positive` và 6 với `neutral`. Câu tiêu cực dài hơn vì thường kèm lý do và đề xuất, nhưng các phân phối chồng lấn nhiều nên độ dài không được dùng làm đặc trưng. 7
2.4 Câu tích cực chủ yếu chứa từ khen (*nhiệt tình*, *dễ*), câu tiêu cực chứa từ góp ý, phàn nàn (*nên*, *cần*, *hơn*), câu trung tính chứa cụm kiểu "không có ý kiến". Từ vựng tách biệt rõ giữa các lớp, nên biểu diễn câu bằng tần suất từ là hướng hợp lý. 7
2.5 Macro-F1 validation của ba bộ phân lớp trên cùng đặc trưng TF-IDF. LinearSVC tốt nhất ở cả hai nhãn (0.773 với `sentiment`, 0.748 với `topic`). 8
2.6 Ma trận nhầm lẫn của mô hình cuối cùng (chuẩn hóa theo hàng). Recall đạt 95.0% với `negative` và 92.8% với `positive` nhưng chỉ 53.3% với `neutral`; với chủ đề, `others` chỉ đạt 56.0%. 10
2.7 Cùng bộ phân lớp LinearSVC, embedding tiếng Việt tăng macro-F1 test từ 0.7388 lên 0.8011 với `sentiment` (+6.2 điểm), còn với `topic` gần như không đổi (0.7516 và 0.7522). 11
2.8 N-gram mạnh nhất theo lớp cảm xúc của LinearSVC trên TF-IDF. `positive` dựa vào *nhiệt_tình*, *tốt*; `negative` dựa vào *chưa*, *cần*, *nên*. Xóa 60 n-gram mạnh nhất làm macro-F1 giảm từ 0.7388 xuống 0.6544, trong khi xóa 60 n-gram ngẫu nhiên chỉ còn 0.7373. 11
2.9 Tỉ lệ đoán sai theo độ dài câu, theo loại từ trong câu và theo chủ đề. Câu có từ đối lập (*nhưng*, *tuy*, ...) sai 18.4%, gấp 2.4 lần câu không có (7.8%); câu 1-5 từ sai nhiều nhất (10.6%); câu thuộc chủ đề `others` sai 30.2%. 12

3.1 Kích thước ảnh rất đa dạng nhưng phần lớn đủ lớn: cạnh ngắn trung vị 700 px, chỉ 9 ảnh (0.04%) dưới 128 px và 347 ảnh (1.4%) dưới 224 px. 17
3.2 Ví dụ các cặp ảnh trùng. Bốn cặp đầu (tên màu đỏ) là cùng một ảnh nhưng được xếp vào hai món khác nhau, như bánh bèo và bánh bột lọc; hai cặp tiếp theo có bản sao ở cả train lẫn validation hoặc test; hai cặp cuối là ảnh gần trùng trong train. 18
3.3 Số ảnh của mỗi món theo tập. Bún bò Huế có nhiều ảnh train nhất (1 071 ảnh), bánh pía ít nhất (310 ảnh), chênh 3.5 lần; ba tập giữ cùng tỉ lệ giữa các món. . . 19
3.4 Bốn ảnh train ngẫu nhiên của mỗi món. Ảnh được chụp từ nhiều góc, nhiều kiểu bày đĩa và điều kiện ánh sáng khác nhau. Nhiều món rất giống nhau, như các món nước (phở, bún bò Huế, hủ tiếu, bún riêu, bánh canh) hay các loại bánh làm từ bột gạo (bánh bèo, bánh đúc, bánh bột lọc). 20
3.5 Độ bão hòa và độ sáng trung bình của ảnh theo món. Trung vị độ bão hòa của các món chỉ trải từ 0.33 (cháo lòng) đến 0.52 (bánh xèo), trong khi khoảng tứ phân vị bên trong một món trung bình đã rộng 0.16, nên màu sắc tổng thể khó đủ để phân biệt 30 món. 21
3.6 Một ảnh train của món bánh xèo và sáu phiên bản tăng cường ngẫu nhiên: món ăn và màu sắc của nó vẫn nhận ra được. 22
3.7 Hàm mất mát train và kết quả validation qua các epoch. Macro-F1 validation tăng từ 0.767 lên 0.817 rồi 0.840; đường chấm là macro-F1 của cách trích đặc trưng (0.694). 23
3.8 Ba mô hình trên cùng tập test, cùng một kiểu đầu phân loại. Macro-F1 tăng từ 0.240 (đặc trưng thủ công) lên 0.695 (ResNet50 trích đặc trưng, +45.5 điểm) và 0.840 (fine-tune nhẹ, thêm 14.5 điểm). 25
3.9 F1 của từng món trên test. F1 trải từ 0.63 (bánh canh) đến 0.97 (bánh mì); ba món khó nhất (bánh canh, bánh đúc, hủ tiếu) đều thuộc nhóm món nước hoặc bánh làm từ bột gạo. 26
3.10 Ma trận nhầm lẫn chuẩn hóa theo hàng. Số màu đỏ là 15 ô ngoài đường chéo từ 5% trở lên, trên tổng số 870 ô: lỗi tập trung vào một số cặp món. 27
3.11 Ba lỗi của mỗi cặp nhầm nhiều nhất (đỏ) cạnh một ảnh đoán đúng của món bị đoán nhầm sang (xanh). 28
3.12 Tỉ lệ đoán sai trên test theo độ tin cậy của mô hình, theo việc ảnh có bản sao mang nhãn khác, theo độ sáng và theo kích thước ảnh. Tỉ lệ sai chung là 16.4%. 29
3.13 Mười sáu ảnh test bị đoán sai với độ tin cậy cao nhất (từ 0.99 trở lên); 3 ảnh mang dấu `[trùng]`, tức có bản sao mang nhãn khác. Độ tin cậy trung vị là 0.54 với ảnh đoán sai và 0.98 với ảnh đoán đúng. 30
3.14 Ba gợi ý của mô hình cho sáu ảnh test đọc từ file gốc, gồm bốn ảnh đoán đúng và hai ảnh đoán sai (tên màu đỏ). Món đúng nằm trong ba gợi ý ở 5 trên 6 ảnh. . 31

Danh sách bảng

1.1 Kết quả giả trên tập test. 2

2.1 Kích thước ba tập và tỉ lệ lớp `neutral`. 4
2.2 Các vấn đề chất lượng dữ liệu và cách xử lý. 5
2.3 LinearSVC trên TF-IDF và trên embedding tiếng Việt (macro-F1 validation). . 9
2.4 Kết quả trên tập test. Hàng in đậm là mô hình cuối cùng, chọn theo macro-F1 validation. 9
2.5 F1 từng lớp so với mô hình Logistic Regression của bài báo gốc trên cùng tập test. 10

3.1 Kích thước ba tập trước và sau khi làm sạch. 16
3.2 Các vấn đề chất lượng dữ liệu và cách xử lý. 17
3.3 Các phép tăng cường dữ liệu và mục tiêu. 22
3.4 Ba mô hình được so sánh. 23
3.5 Kết quả trên tập test (5 040 ảnh). Hàng in đậm là mô hình cuối cùng, chọn theo macro-F1 validation. 24
3.6 Năm cặp món bị nhầm nhiều nhất (tỉ lệ trên số ảnh test của món thực tế). 27

Chương 1

Phân tích dữ liệu dạng bảng

1.1 Bài toán và bộ dữ liệu

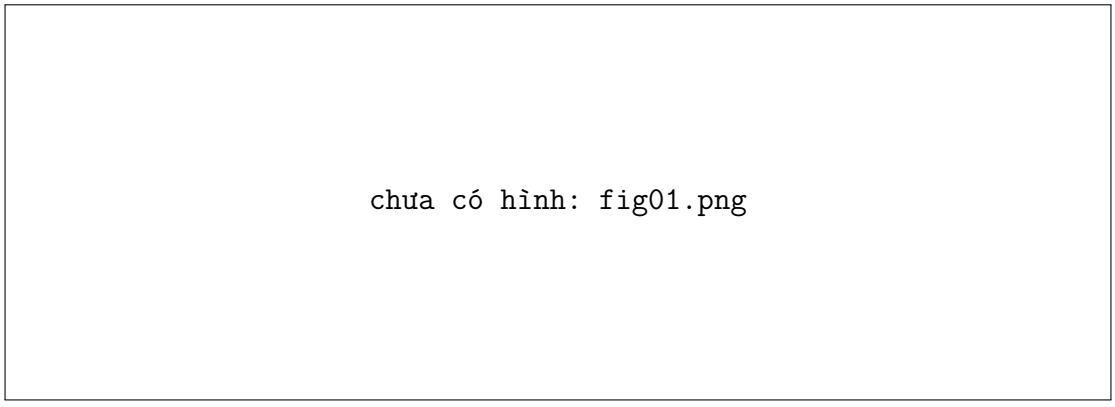
(Nội dung giả.) Mô tả bài toán, nguồn dữ liệu, quy mô và giấy phép.

1.2 Kiểm tra chất lượng dữ liệu

(Nội dung giả.)

1.3 Phân tích khám phá (EDA)

(Nội dung giả.)



Hình 1.1: Chú thích giả: câu nêu kết luận của hình.

1.4 Chuẩn bị dữ liệu

(Nội dung giả.)

1.5 Xây dựng mô hình

(Nội dung giả.)

1.6 Đánh giá trên tập test

Bảng 1.1: Kết quả giả trên tập test.

Mô hình	Macro-F1
Baseline	0.40
Mô hình B	0.72

1.7 Kết luận

(Nội dung giả.) Kết quả chính, hạn chế, hướng mở rộng.

Chương 2

Phân loại phản hồi của sinh viên theo cảm xúc và chủ đề

2.1 Bài toán và hướng tiếp cận

Mỗi học kỳ, Trường Đại học Công nghệ Thông tin (ĐHQG-HCM) thu thập ý kiến phản hồi tự do của sinh viên về giảng viên, chương trình đào tạo và cơ sở vật chất. Với hơn 16 000 câu phản hồi, việc đọc và phân loại thủ công tốn nhiều thời gian. Bài tập này xây dựng mô hình tự động gán cho mỗi câu phản hồi hai nhãn:

- **Cảm xúc** (`sentiment`, nhiệm vụ chính): `negative`, `neutral`, `positive`.
- **Chủ đề** (`topic`, nhiệm vụ phụ): `lecturer` (giảng viên), `program` (chương trình đào tạo), `facility` (cơ sở vật chất), `others` (chủ đề khác).

Đây là bài toán phân tích cảm xúc, một dạng phân loại văn bản có giám sát. Vì mô hình phân loại chỉ làm việc với số, mỗi câu được biểu diễn thành một vector. Quy trình gồm các bước: kiểm tra chất lượng và phân tích khám phá dữ liệu; tiền xử lý văn bản (làm sạch, đổi viết tắt, tách từ tiếng Việt); so sánh ba bộ phân lớp của scikit-learn trên đặc trưng TF-IDF; thay TF-IDF bằng embedding câu tiếng Việt cho bộ phân lớp tốt nhất; đánh giá một lần trên tập test và phân tích lỗi. Notebook chạy được trên Google Colab với *Runtime* > *Run all*.

2.2 Bộ dữ liệu

- **Nguồn:** bộ dữ liệu UIT-VSFC (Vietnamese Students' Feedback Corpus) [1], tải từ trang Hugging Face của nhóm tác giả (`uitnlp/vietnamese_students_feedback`), không cần đăng nhập.
- **Giấy phép:** dùng cho mục đích nghiên cứu theo thỏa thuận của nhóm tác giả. Nhóm trích dẫn nguồn và không đưa dữ liệu lên repo.

- **Nội dung:** câu phản hồi trong khảo sát cuối học kỳ, từ năm học 2014-2015 đến 2016-2017, được gán nhãn thủ công. Văn bản đã được viết thường, tách dấu câu, ẩn danh tên giảng viên (`wzjwz<số>`) và chuẩn hóa viết tắt trước khi công bố.
- **Quy tắc gán nhãn:** `negative` gồm cả lời phàn nàn lẫn đề nghị cải thiện; `neutral` là câu không nêu ý kiến hoặc chưa trọn ý, kể cả lời cảm ơn; câu vừa khen vừa chê được gán theo ý mạnh hơn.
- **Độ tin cậy của nhãn:** mức đồng thuận giữa người gán nhãn là 91.2% với cảm xúc nhưng chỉ 71.07% với chủ đề, nên nhãn chủ đề kém chắc chắn hơn.

Nhóm giữ nguyên cách chia train / dev / test của tác giả và dùng làm train / val / test, để kết quả so sánh được với bài báo gốc (Bảng 2.1). Bộ dữ liệu đáp ứng yêu cầu của đề với dữ liệu văn bản: 16 175 câu, nhiều hơn mức tối thiểu 2 000, và 99.9% số câu có chữ tiếng Việt có dấu.

Bảng 2.1: Kích thước ba tập và tỉ lệ lớp `neutral`.

Tập	Số câu	Tỉ lệ	Tỉ lệ `neutral`
train	11 426	70.6%	4.0%
val	1 583	9.8%	4.6%
test	3 166	19.6%	5.3%

2.3 Kiểm tra chất lượng dữ liệu

Mục này chỉ chẩn đoán vấn đề; cách xử lý được áp dụng ở bước tiền xử lý. Bảng 2.2 tổng hợp kết quả.

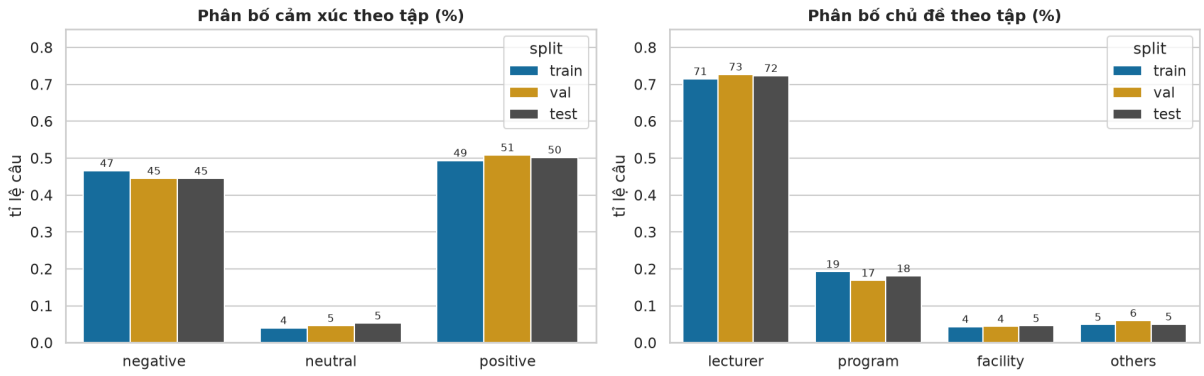
Bảng 2.2: Các vấn đề chất lượng dữ liệu và cách xử lý.

Vấn đề	Kết quả kiểm tra	Cách xử lý
Giá trị thiếu, câu rỗng	0 câu	nếu có thì bỏ khỏi train/val/test
Unicode không ở dạng NFC	0 câu	vẫn chuẩn hóa NFC cho câu mới
Câu trùng trong train	1 câu, hai bản mang nhãn trái ngược	bỏ bản lặp khỏi train
Câu train có trong val/test	0 câu	nếu có thì bỏ khỏi train
Câu rất ngắn / rất dài	141 câu không quá 2 từ, 663 câu trên 30 từ	giữ lại, vì đều là câu trả lời thật
Tên ẩn danh `wzjwz<số>`	211 câu, 233 mã khác nhau	thay bằng một token chung `personname`
Biểu tượng cảm xúc (`colonsmile`, ...)	85 câu	giữ lại vì mang cảm xúc
Viết tắt / teencode	25 token trong 21 câu	đổi sang dạng đầy đủ theo từ điển viết tắt
Nhãn mất cân bằng	`neutral` chỉ 4.0% tập train	chọn mô hình theo macro-F1, dùng `class_weight="balanced"`

Từ điển viết tắt (gồm các cặp từ viết tắt và dạng đầy đủ) được xây dựng bằng cách tách toàn bộ dữ liệu thành từ, dùng LLM rà soát để tìm từ viết tắt và cách viết sai, rồi kiểm tra thủ công từng từ trong câu gốc. Các từ dễ hiểu sai bị loại, ví dụ `k` (phần còn lại của `k6`, `320k` sau khi bỏ chữ số) và `bt` (có thể là "bài tập" hoặc "bình thường"). Từ điển cũng có thêm các cách viết tắt phổ biến như `gv`, `sv` để xử lý câu mới do người dùng nhập. Kết quả cho thấy dữ liệu gần như không có viết tắt, đúng như bài báo mô tả.

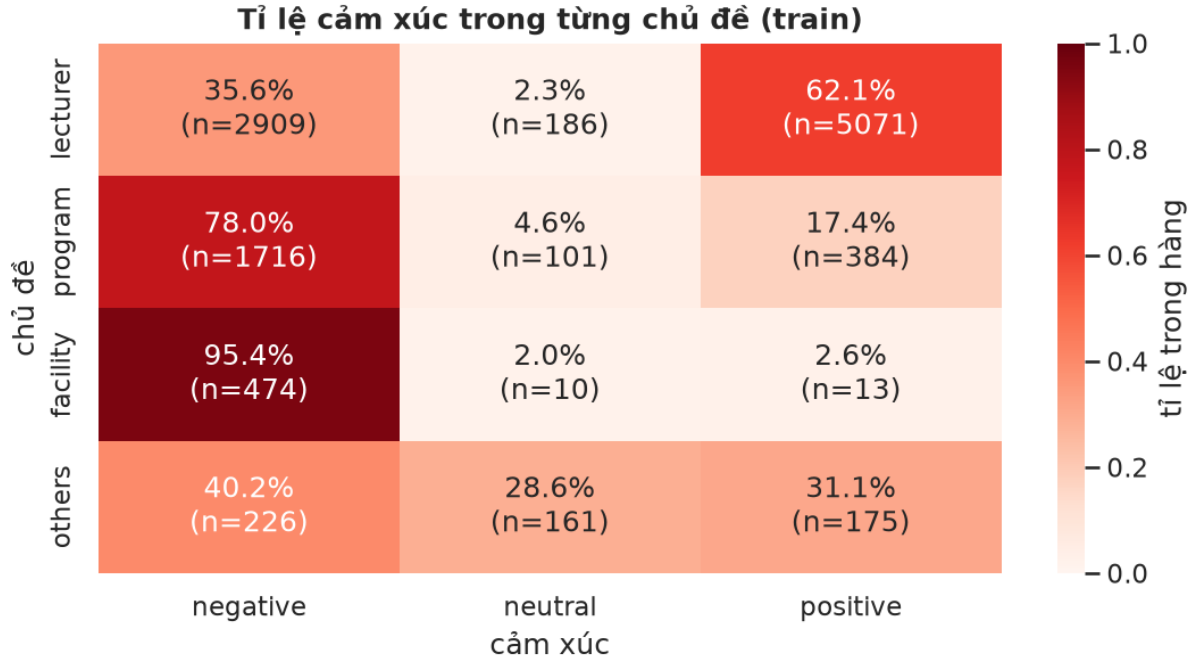
2.4 Phân tích khám phá dữ liệu

Phân tích khám phá chỉ dùng tập train, trừ Hình 2.1 so sánh ba tập.



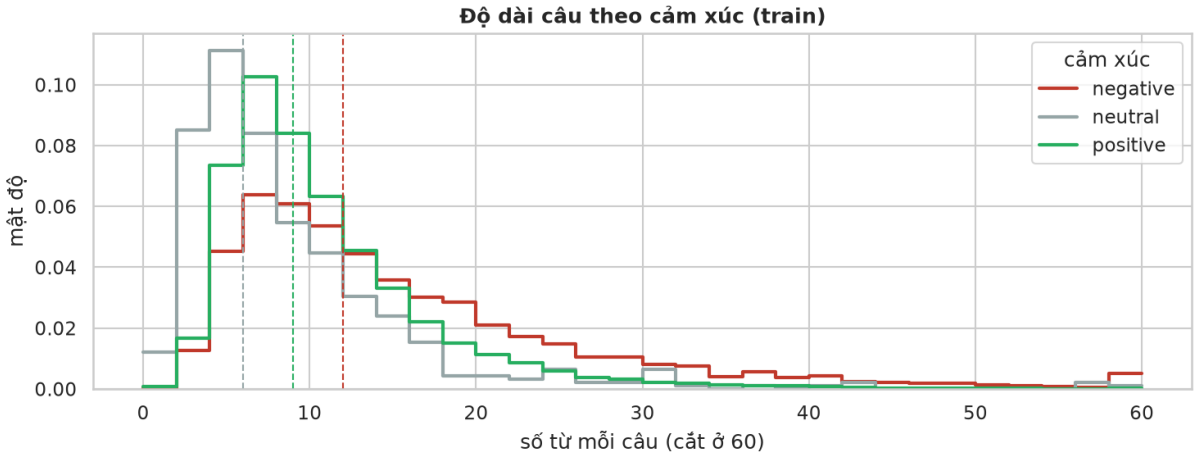
Hình 2.1: Cả hai nhãn đều mất cân bằng: trong train, `neutral` chỉ chiếm 4.0% và chủ đề `lecturer` chiếm 71.5%. Tỉ lệ giữa ba tập chênh nhau tối đa 2.1 điểm phần trăm.

Vì lớp `neutral` rất nhỏ, accuracy sẽ che mất việc mô hình nhận sai lớp này. Do đó mô hình được chọn theo macro-F1, thước đo lấy trung bình F1 của các lớp với trọng số như nhau.



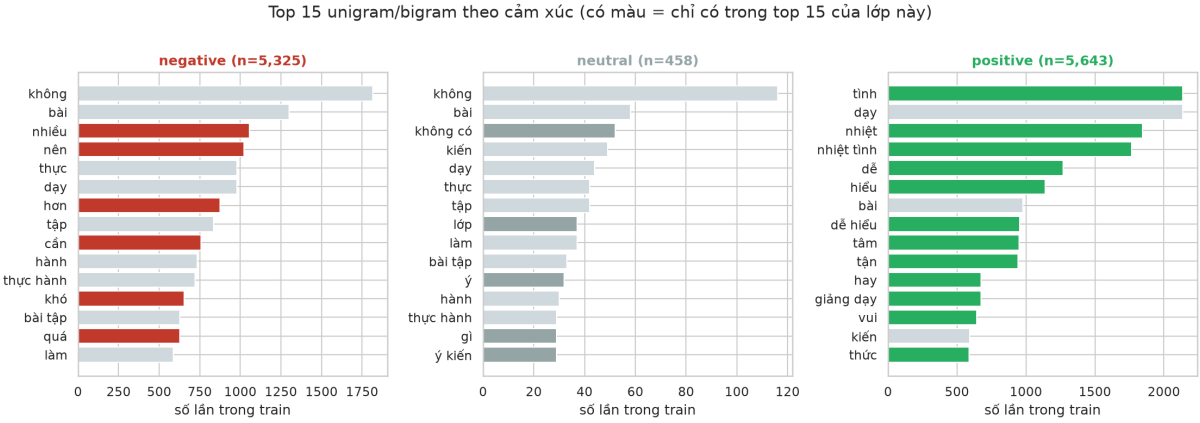
Hình 2.2: Tỉ lệ và số câu tiêu cực theo chủ đề: `facility` 95.4% (474 câu), `program` 78.0% (1 716 câu), `others` 40.2% (226 câu), `lecturer` 35.6% (2 909 câu). Phản hồi về cơ sở vật chất ít nhưng gần như toàn là phàn nàn, còn giảng viên chiếm 54.6% tổng số câu tiêu cực.

Tỉ lệ từng cặp chủ đề và cảm xúc trên tập train khớp với bảng thống kê của bài báo gốc (chênh dưới 1 điểm phần trăm ở mọi ô), trừ ô `lecturer` x `positive` (44.38% so với 33.57%). Ô này có vẻ là lỗi đánh máy của bài báo: hàng `lecturer` của bài báo chỉ cộng lại được 60.76% thay vì 71.76%.



Hình 2.3: Trung vị độ dài là 12 từ với câu `negative`, 9 với `positive` và 6 với `neutral`. Câu tiêu cực dài hơn vì thường kèm lý do và đề xuất, nhưng các phân phối chồng lấn nhiều nên độ dài không được dùng làm đặc trưng.

Chia theo khoảng 5 từ như bài báo, 74.6% số câu train không quá 15 từ, thấp hơn mức "hơn 83%" của bài báo, có thể vì bài báo đếm từ sau khi tách từ còn nhóm đếm âm tiết. Khoảng 43% câu `others` chỉ có 1-5 từ.



Hình 2.4: Câu tích cực chủ yếu chứa từ khen (*nhiệt tình*, *dễ*), câu tiêu cực chứa từ góp ý, phàn nàn (*nên*, *cần*, *hơn*), câu trung tính chứa cụm kiểu "không có ý kiến". Từ vựng tách biệt rõ giữa các lớp, nên biểu diễn câu bằng tần suất từ là hướng hợp lý.

2.5 Tiền xử lý dữ liệu

Các bước được áp dụng theo thứ tự sau. Các quy tắc theo từng dòng được áp dụng như nhau cho mọi tập, còn mọi thống kê học từ dữ liệu (từ vựng TF-IDF, bộ mã hóa nhãn) chỉ được fit trên train; validation và test không bị bỏ dòng nào.

1. Chuẩn hóa Unicode NFC và bỏ câu trùng khỏi train: 16 175 câu còn 16 174.

2. Hàm `clean_text()`: viết thường, thay tên ẩn danh bằng `personname`, bỏ dấu câu và chữ số, đổi viết tắt theo từ điển viết tắt, gộp khoảng trắng.

3. Tách từ tiếng Việt bằng `pyvi`: nối các âm tiết của một từ bằng dấu _ (ví dụ *giảng viên* thành `giảng_viên`); tìm được 49 749 từ nhiều âm tiết. Văn bản đã tách từ dùng cho TF-IDF, văn bản chưa tách từ dùng cho mô hình embedding.

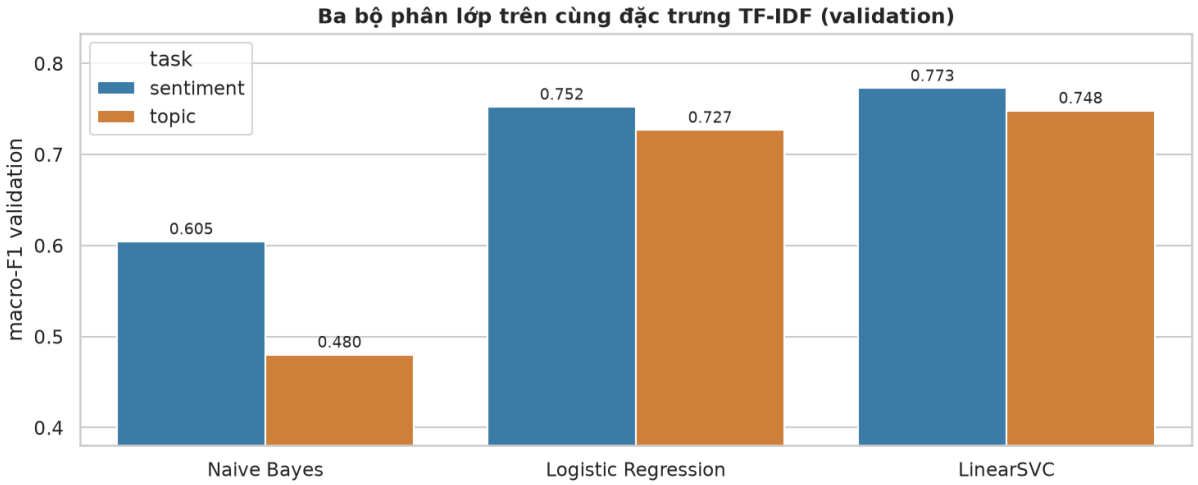
4. Mã hóa nhãn bằng `LabelEncoder`.

5. Biểu diễn TF-IDF: unigram và bigram, bỏ n-gram chỉ gặp một lần, chuẩn hóa L2 để câu dài và câu ngắn có cùng thang đo. Từ vựng có 13 025 đặc trưng.

2.6 Xây dựng mô hình

Mô hình được huấn luyện trên train và chọn theo macro-F1 trên validation; tập test chỉ dùng một lần. Ba bộ phân lớp của scikit-learn được so sánh với tham số mặc định: Naive Bayes (`MultinomialNB`), Logistic Regression và LinearSVC. Bài báo gốc cũng dùng Logistic Regression làm baseline. Vì lớp `neutral` rất nhỏ, Logistic Regression và LinearSVC luôn dùng `class_weight="balanced"` để lỗi ở lớp nhỏ bị phạt nặng hơn.

2.6.1 So sánh các bộ phân lớp trên TF-IDF



Hình 2.5: Macro-F1 validation của ba bộ phân lớp trên cùng đặc trưng TF-IDF. LinearSVC tốt nhất ở cả hai nhãn (0.773 với `sentiment`, 0.748 với `topic`).

LinearSVC đạt macro-F1 validation cao nhất ở cả hai nhãn, Logistic Regression kém khoảng 2 điểm, còn Naive Bayes thấp hơn hẳn (0.605 và 0.480) dù accuracy vẫn cao (0.886 với `sentiment`): mô hình này làm tốt ở lớp lớn nhưng kém ở các lớp nhỏ như `neutral` và `others`. Đây là ví dụ cho thấy vì sao phải chọn mô hình theo macro-F1.

2.6.2 Embedding tiếng Việt có giúp bộ phân lớp tốt nhất không?

Giữ LinearSVC, nhóm thay TF-IDF bằng embedding câu của `AITeamVN/Vietnamese_Embedding` [2], mô hình embedding câu tiếng Việt được fine-tune từ BGE-M3 (vector 1024 chiều, giấy phép Apache 2.0). Mô hình được dùng như một hàm trích đặc trưng có sẵn, không fine-tune thêm.

Bảng 2.3: LinearSVC trên TF-IDF và trên embedding tiếng Việt (macro-F1 validation).

Nhãn	TF-IDF	Embedding
`sentiment`	0.7729	**0.8244**
`topic`	0.7484	**0.7496**

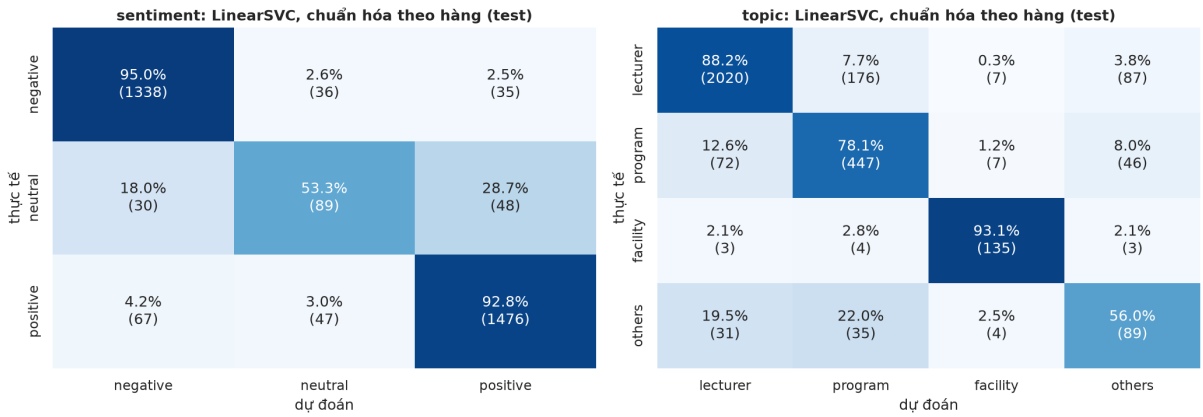
Với `sentiment`, embedding tốt hơn rõ rệt (+5.2 điểm); với `topic`, hai cách gần như bằng nhau. Có thể vì cảm xúc phụ thuộc vào nghĩa của cả câu, còn chủ đề thường lộ ra qua vài từ khóa mà TF-IDF đã bắt được. Theo cách chọn mô hình, **embedding tiếng Việt + LinearSVC** là mô hình cuối cùng cho cả hai nhãn.

2.7 Đánh giá trên tập test

Bảng 2.4: Kết quả trên tập test. Hàng in đậm là mô hình cuối cùng, chọn theo macro-F1 validation.

Nhãn	Mô hình	Accuracy	Macro-F1	Weighted-F1
`sentiment`	Naive Bayes, TF-IDF	0.8699	0.5955	0.8466
	Logistic Regression, TF-IDF	0.8692	0.7201	0.8748
	LinearSVC, TF-IDF	0.8961	0.7388	0.8917
	LinearSVC, embedding	**0.9169**	**0.8011**	**0.9172**
`topic`	Naive Bayes, TF-IDF	0.8184	0.5440	0.7809
	Logistic Regression, TF-IDF	0.8143	0.7283	0.8282
	LinearSVC, TF-IDF	0.8547	0.7516	0.8562
	LinearSVC, embedding	**0.8500**	**0.7522**	**0.8574**

Thứ tự các mô hình trên test giống trên validation ở cả hai nhãn. Weighted-F1 của mô hình cuối cùng (0.917 và 0.857) cao hơn mô hình Logistic Regression của bài báo gốc (khoảng 0.88 và 0.84). Với `topic`, embedding và TF-IDF gần như bằng nhau.



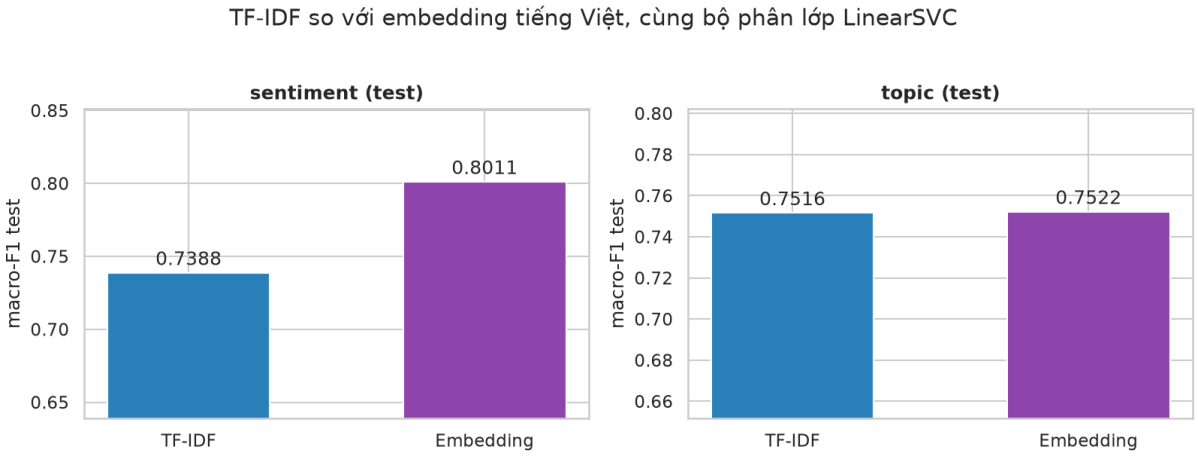
Hình 2.6: Ma trận nhầm lẫn của mô hình cuối cùng (chuẩn hóa theo hàng). Recall đạt 95.0% với `negative` và 92.8% với `positive` nhưng chỉ 53.3% với `neutral`; với chủ đề, `others` chỉ đạt 56.0%.

Bảng 2.5: F1 từng lớp so với mô hình Logistic Regression của bài báo gốc trên cùng tập test.

Nhãn	Lớp	Nhóm	Bài báo	Chênh lệch
`sentiment`	`negative`	0.9409	0.9052	+0.036
	`neutral`	0.5251	0.3399	+0.185
	`positive`	0.9374	0.9132	+0.024
`topic`	`facility`	0.9060	0.8873	+0.019
	`lecturer`	0.9149	0.9112	+0.004
	`others`	0.4635	0.3810	+0.083
	`program`	0.7245	0.6719	+0.053

Mô hình cuối cùng có F1 cao hơn bài báo ở cả 7 lớp, tăng nhiều nhất ở các lớp nhỏ và khó (`neutral`, `others`, `program`). Tuy vậy `neutral` (0.53) và `others` (0.46) vẫn là hai lớp yếu nhất.

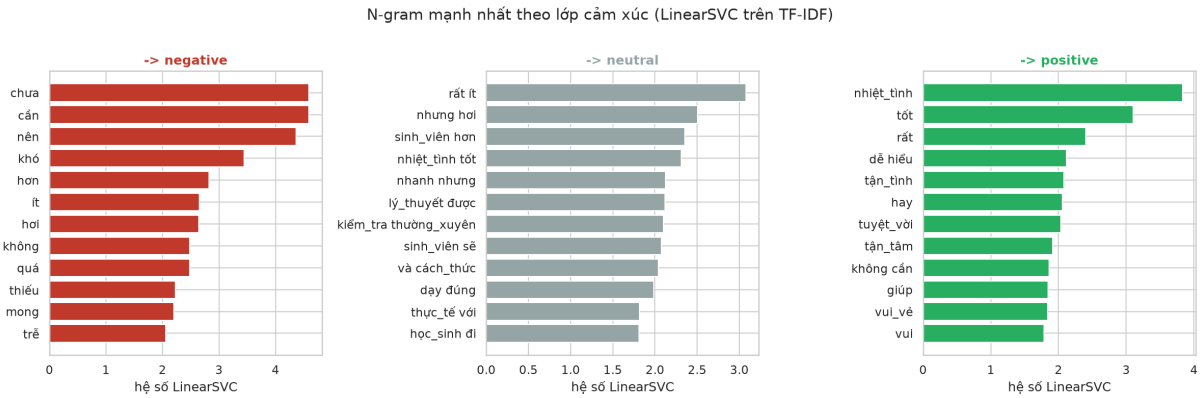
2.7.1 TF-IDF hay embedding tiếng Việt?



Hình 2.7: Cùng bộ phân lớp LinearSVC, embedding tiếng Việt tăng macro-F1 test từ 0.7388 lên 0.8011 với `sentiment` (+6.2 điểm), còn với `topic` gần như không đổi (0.7516 và 0.7522).

2.7.2 Mô hình dựa vào những từ nào?

Mô hình cuối cùng dùng embedding 1024 chiều, các chiều này không ứng với từ nào nên không đọc được mô hình dựa vào từ gì. Vì vậy nhóm phân tích mô hình TF-IDF tốt nhất (LinearSVC trên TF-IDF), mô hình có một trọng số cho mỗi cặp (lớp, n-gram). Để kiểm chứng các n-gram mạnh nhất có thật sự quyết định dự đoán, nhóm xóa chúng khỏi vector test và so với việc xóa cùng số lượng n-gram ngẫu nhiên.

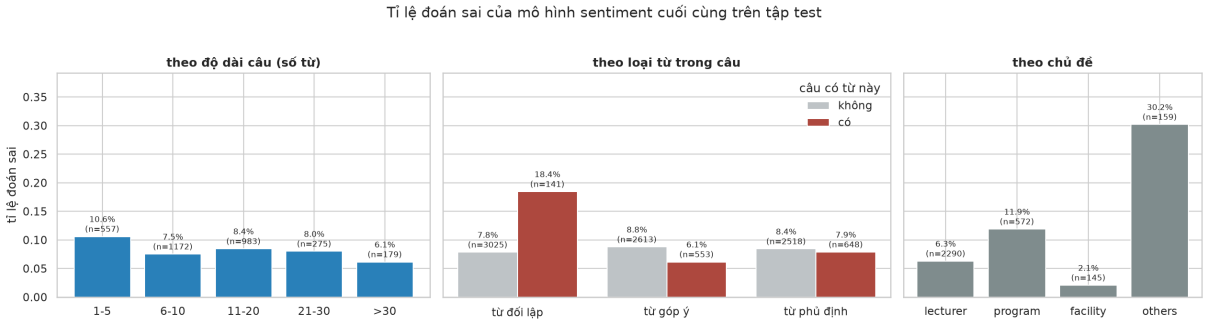


Hình 2.8: N-gram mạnh nhất theo lớp cảm xúc của LinearSVC trên TF-IDF. `positive` dựa vào *nhiệt_tình*, *tốt*; `negative` dựa vào *chưa*, *cần*, *nên*. Xóa 60 n-gram mạnh nhất làm macro-F1 giảm từ 0.7388 xuống 0.6544, trong khi xóa 60 n-gram ngẫu nhiên chỉ còn 0.7373.

Các động từ góp ý *cần*, *nên* là tín hiệu `negative` mạnh vì theo quy tắc gán nhãn, đề nghị cải thiện được tính là tiêu cực. Các n-gram mạnh nhất của `neutral` (*rất ít*, *nhưng hơi*) mang sắc thái chê nhẹ hoặc lưng chừng, cho thấy lớp này không có từ vựng riêng rõ ràng. Với chủ đề cơ sở vật chất, các từ đẩy câu về tiêu cực mạnh nhất là *máy_chiếu*, *phòng*, *trang thiết_bị*, *wifi*.

2.7.3 Mô hình sai ở đâu?

Mô hình cảm xúc cuối cùng đoán sai 263 trên 3 166 câu test (8.3%). Kiểu sai nhiều nhất là câu `positive` bị đoán thành `negative` (25.5% số lỗi), và 61.2% số lỗi có dính đến lớp `neutral` dù lớp này chỉ có 167 câu.



Hình 2.9: Tỉ lệ đoán sai theo độ dài câu, theo loại từ trong câu và theo chủ đề. Câu có từ đối lập (*nhưng*, *tuy*, ...) sai 18.4%, gấp 2.4 lần câu không có (7.8%); câu 1-5 từ sai nhiều nhất (10.6%); câu thuộc chủ đề `others` sai 30.2%.

Từ phủ định gần như không ảnh hưởng đến tỉ lệ sai (7.9% so với 8.4%), còn câu có từ góp ý lại ít sai hơn (6.1% so với 8.8%) vì dữ liệu luôn gán lời góp ý là `negative`. Nguồn lỗi chính là câu vừa khen vừa chê, một giới hạn của việc gán một nhãn cho cả câu chứ không chỉ của mô hình.

2.8 Dự đoán phản hồi mới

Hàm `predict()` chạy toàn bộ quy trình trên văn bản thô: làm sạch bằng cùng hàm `clean_text()`, mã hóa câu bằng mô hình embedding, rồi dự đoán bằng hai mô hình cuối cùng. Câu có viết tắt như *"gv dạy ko hiểu gì cả, nói quá nhanh"* được xếp `negative`, `lecturer`; câu đề nghị *"nên cho thêm bài tập thực hành cuối mỗi chương"* được xếp `negative`, `program`, đúng quy tắc gán nhãn. Câu *"thầy dạy dễ hiểu nhưng phòng học nóng quá"* chỉ nhận một cặp nhãn (`negative`, `lecturer`); khi tách câu tại từ *nhưng*, hai mệnh đề được xếp đúng là (`positive`, `lecturer`) và (`negative`, `facility`).

2.9 Kết luận

Mô hình cuối cùng, embedding tiếng Việt kết hợp LinearSVC, đạt macro-F1 0.8011 với cảm xúc và 0.7522 với chủ đề trên tập test, cao hơn baseline Naive Bayes (0.5955 và 0.5440) và cao hơn mô hình Logistic Regression của bài báo gốc ở mọi lớp. Embedding tiếng Việt giúp ích rõ với nhãn cảm xúc (+6.2 điểm so với TF-IDF) nhưng gần như không thay đổi kết quả với nhãn chủ đề.

Hạn chế

- Mỗi câu chỉ có một nhãn, nên câu vừa khen vừa chê không được biểu diễn đúng và là nguồn lỗi chính.
- Lớp `neutral` và `others` vẫn yếu (F1 khoảng 0.53 và 0.46): hai lớp nhỏ, không có từ vựng riêng và có một số nhãn mơ hồ.
- Theo quy tắc gán nhãn, lời đề nghị được tính là `negative`, nên lớp này lẫn cả phàn nàn và góp ý.
- Các bộ phân lớp dùng tham số mặc định, chưa được tinh chỉnh; embedding chỉ được dùng làm hàm trích đặc trưng.
- Dữ liệu đến từ một trường đại học và đã được chuẩn hóa, nên kết quả với phản hồi kiểu mạng xã hội có thể thấp hơn.

Hướng mở rộng

Fine-tune trực tiếp mô hình embedding hoặc PhoBERT trên dữ liệu này; gán nhãn theo mệnh đề để xử lý câu trộn lẫn; thêm nhãn riêng cho lời góp ý; thu thập phản hồi từ khoa hoặc trường khác để kiểm tra khả năng tổng quát hóa.

Tài liệu tham khảo

[1] K. V. Nguyen, V. D. Nguyen, P. X. V. Nguyen, T. T. H. Truong, N. L.-T. Nguyen. *UIT-VSFC: Vietnamese Students' Feedback Corpus for Sentiment Analysis*. 10th International Conference on Knowledge and Systems Engineering (KSE), 2018, tr. 19-24.

[2] AITeamVN. *Vietnamese_Embedding*. Hugging Face, https://huggingface.co/AITeamVN/Vietnamese_Embedding.

Chương 3

Nhận diện món ăn Việt Nam qua ảnh

3.1 Bài toán và hướng tiếp cận

Một ứng dụng ẩm thực hoặc du lịch cho phép người dùng chụp ảnh món ăn và tự động cho biết tên món (phở, bún bò Huế, bánh xèo, cơm tấm, ...). Bài tập này xây dựng mô hình nhận một ảnh và dự đoán món ăn trong ảnh, trong 30 món ăn Việt Nam phổ biến. Vì ứng dụng có thể hiện vài gợi ý cùng lúc, ngoài accuracy và macro-F1, nhóm còn báo cáo top-3 và top-5 accuracy: tỉ lệ ảnh có món đúng nằm trong 3 hoặc 5 dự đoán đầu tiên.

Đây là bài toán phân loại ảnh có giám sát với 30 lớp. Hướng chính là học sâu với một mạng đã huấn luyện sẵn: ResNet50 [2] được dùng theo hai cách mà đề yêu cầu, trích đặc trưng (giữ nguyên mạng) và fine-tune nhẹ (học lại khối cuối), và được so sánh với một baseline dùng đặc trưng thủ công (histogram màu và SIFT). Cả ba mô hình có cùng một kiểu đầu phân loại, nên khác biệt giữa chúng chỉ đến từ đặc trưng. Quy trình gồm: đưa dữ liệu về cấu trúc thư mục chuẩn cho phân loại ảnh; kiểm tra chất lượng và phân tích khám phá; tiền xử lý và tăng cường dữ liệu; xây dựng ba mô hình; đánh giá một lần trên tập test và phân tích lỗi. Notebook chạy được trên Google Colab với *Runtime* > *Run all* (cần runtime GPU).

3.2 Bộ dữ liệu

- **Nguồn:** bộ dữ liệu 30VNFoods [1], bản gốc được đăng trên Kaggle. Notebook tải bản sao công khai trên Hugging Face (`vuongnhathien/30VNFoods`), không cần đăng nhập.
- **Giấy phép:** dữ liệu được phát hành theo giấy phép CC BY-NC-SA 4.0, chỉ dùng cho mục đích phi thương mại và phải ghi nguồn. Nhóm không đưa ảnh lên repo.
- **Nội dung:** ảnh chụp 30 món ăn Việt Nam thu thập từ Internet. Mỗi ảnh có một nhãn là tên món, lưu bằng tên thư mục chứa ảnh (tên món viết không dấu).
- **Kết quả gốc:** mô hình tốt nhất của bài báo đạt accuracy 77.54% và top-5 accuracy 96.07% trên tập test.

Bộ dữ liệu có 25 136 ảnh của 30 món, nhiều hơn mức tối thiểu 5 000 ảnh và 3 lớp mà đề yêu cầu cho dữ liệu ảnh, và là ảnh chụp thực tế chứ không phải bộ dữ liệu mẫu như MNIST hay CIFAR-10. Tác giả đã chia sẵn thành train (69.9%), val (10.0%) và test (20.1%); nhóm giữ nguyên cách chia này để kết quả so sánh được với bài báo gốc (Bảng 3.1). Kích thước ảnh rất khác nhau: cạnh ngắn từ 83 đến 4 912 px, trung vị 700 px, và chỉ 9 ảnh có cạnh ngắn dưới mức 128 px mà đề khuyến nghị.

Cấu trúc thư mục. Mỗi ảnh chỉ có một nhãn, nên nhãn được lưu bằng thư mục chứa ảnh. Notebook đưa dữ liệu về đúng cấu trúc mà Ultralytics YOLO dùng cho bài toán phân loại: một thư mục cho mỗi tập, bên trong là một thư mục con cho mỗi món. File `labels.csv` liệt kê mọi ảnh với tập và nhãn của nó.

```
data/
  train/
    Banh beo/   1.jpg  10.jpg  ...
    Banh bot loc/
    ...         (30 thu muc, moi mon mot thu muc)
  val/          (cung cau truc)
  test/         (cung cau truc)
  labels.csv    (path, split, label)
```

Bảng 3.1: Kích thước ba tập trước và sau khi làm sạch.

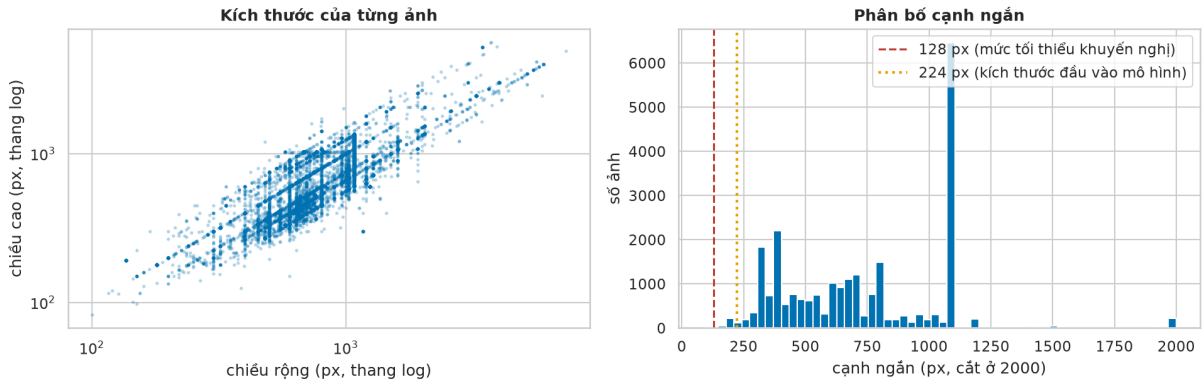
Tập	Ban đầu	Ảnh nhỏ	Ảnh trùng	Còn lại	Số ảnh mỗi món
train	17 581	5	361	17 215	306 - 1 047
val	2 515	0	0	2 515	45 - 153
test	5 040	0	0	5 040	89 - 306

3.3 Kiểm tra chất lượng dữ liệu

Mỗi ảnh được mở một lần để ghi lại: file có đọc được không, định dạng thật theo nội dung file, chế độ màu, kích thước, mã băm cảm nhận (pHash) và độ bão hòa, độ sáng trung bình. Bảng 3.2 tổng hợp kết quả.

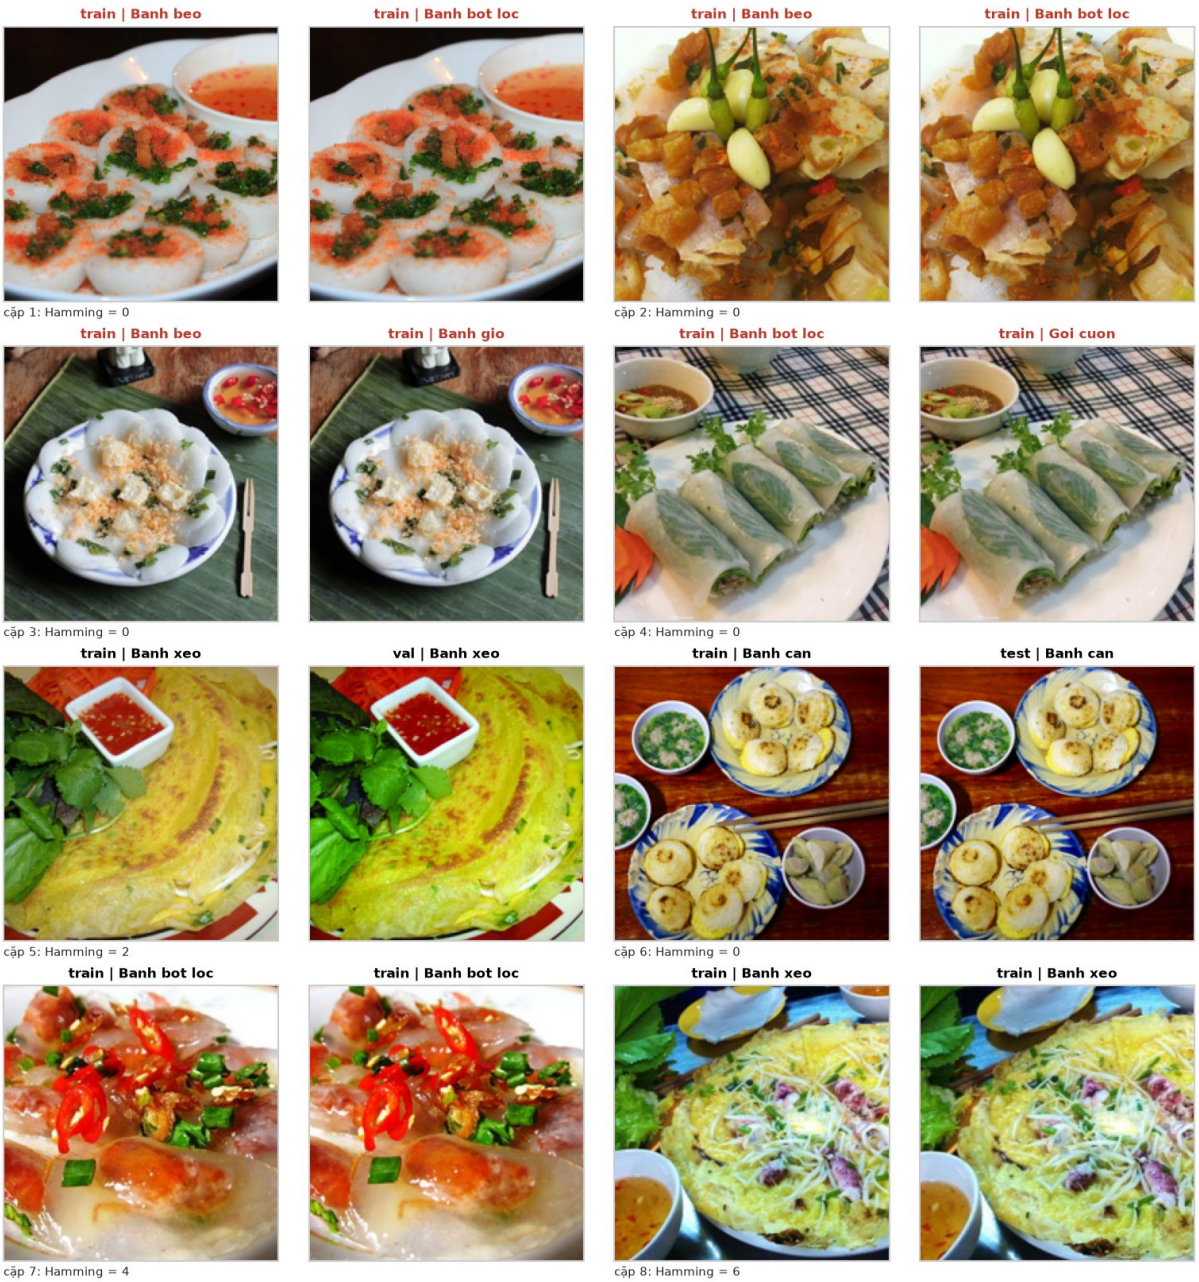
Bảng 3.2: Các vấn đề chất lượng dữ liệu và cách xử lý.

Vấn đề	Kết quả kiểm tra	Cách xử lý
File lỗi	0 file	nếu có thì bỏ khỏi train/val/test
Định dạng khác JPEG	129 file (PNG, MPO, BMP) có đuôi `.jpg`	giữ lại, thư viện đọc ảnh theo nội dung file
Chế độ màu khác RGB	0 ảnh	vẫn đổi sang RGB, cần cho ảnh mới
Cạnh ngắn dưới 128 px	9 ảnh (5 ở train)	bỏ khỏi train; giữ ở val/test và phóng to
Kích thước khác nhau	cạnh ngắn từ 83 đến 4 912 px, trung vị 700 px	đưa về 224 x 224
Ảnh trùng giữa train và val/test	186 cặp	bỏ khỏi train
Ảnh trùng mang nhãn khác	65 cặp	bỏ khỏi train; đánh dấu ở val/test
Ảnh trùng cùng nhãn trong train	153 cặp	giữ một bản cho mỗi nhóm, bỏ các bản còn lại khỏi train
Lớp mất cân bằng	món nhiều ảnh nhất gấp 3.5 lần món ít nhất	chọn mô hình theo macro-F1



Hình 3.1: Kích thước ảnh rất đa dạng nhưng phần lớn đủ lớn: cạnh ngắn trung vị 700 px, chỉ 9 ảnh (0.04%) dưới 128 px và 347 ảnh (1.4%) dưới 224 px.

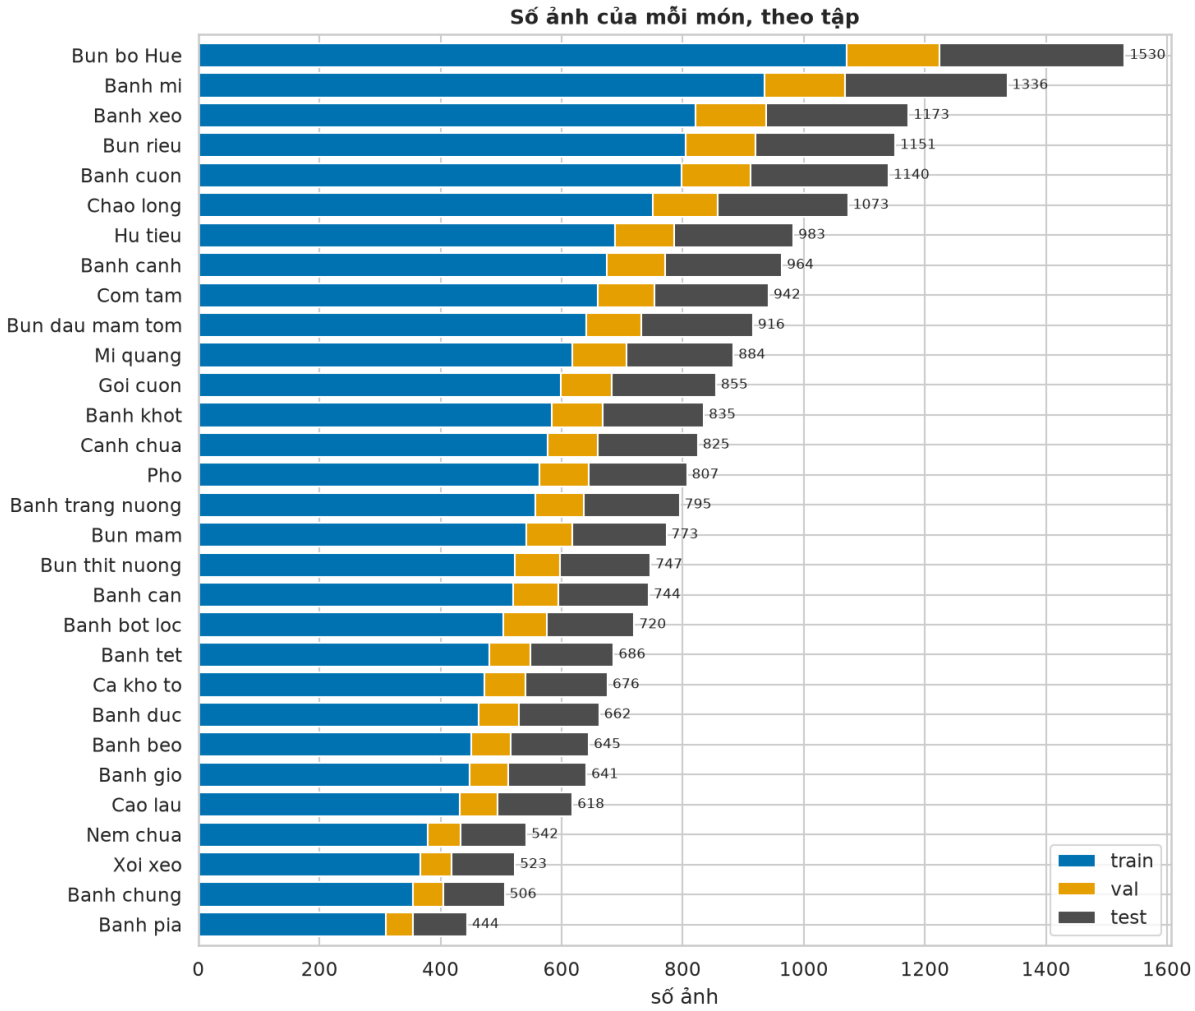
Để tìm ảnh trùng, mỗi ảnh được tóm tắt bằng pHash, một mã 64 bit mô tả cấu trúc tổng thể của ảnh: hai bản của cùng một ảnh (dù đã bị nén lại, thu nhỏ hay cắt nhẹ) có mã giống hoặc gần giống nhau. Nhóm so sánh toàn bộ 315 896 680 cặp ảnh bằng phép XOR và đếm bit của numpy, và coi hai ảnh là trùng nếu mã của chúng khác nhau không quá 6 bit. Kết quả có 403 cặp trùng (239 cặp trùng hoàn toàn, 164 cặp gần trùng), liên quan đến 757 ảnh (3.0% bộ dữ liệu).



Hình 3.2: Ví dụ các cặp ảnh trùng. Bốn cặp đầu (tên màu đỏ) là cùng một ảnh nhưng được xếp vào hai món khác nhau, như bánh bèo và bánh bột lọc; hai cặp tiếp theo có bản sao ở cả train lẫn validation hoặc test; hai cặp cuối là ảnh gần trùng trong train.

3.4 Phân tích khám phá dữ liệu

Phân tích khám phá chỉ dùng tập train, trừ Hình 3.3 so sánh ba tập.

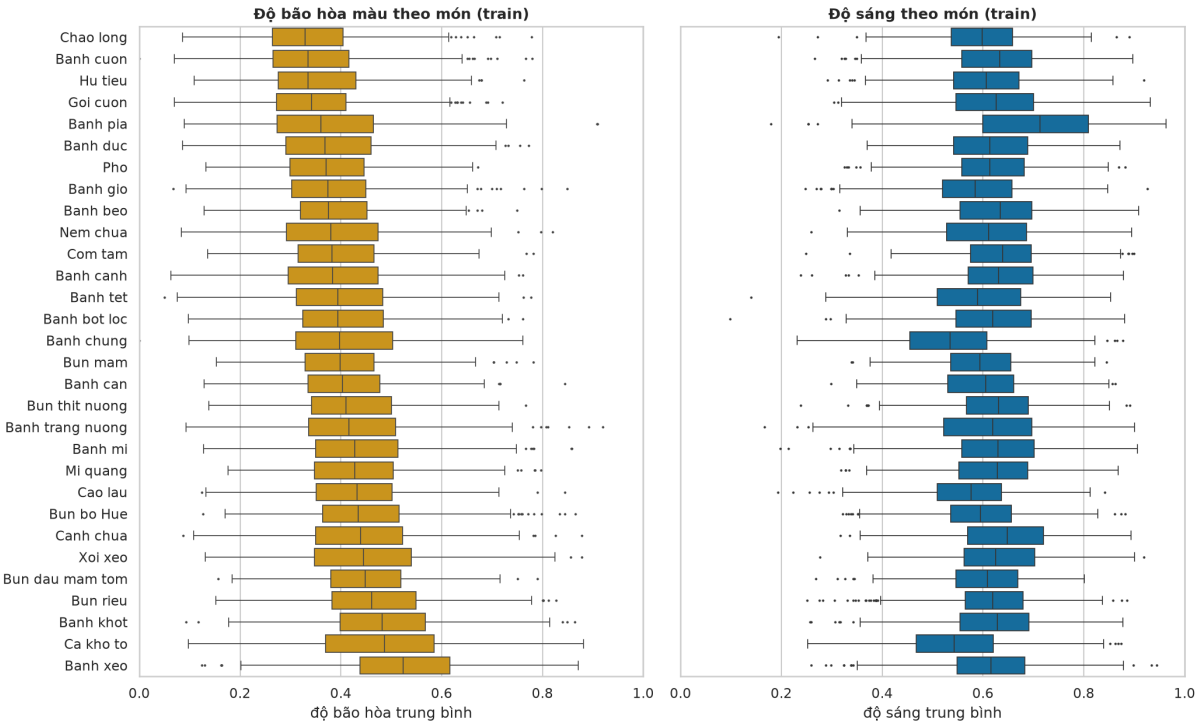


Hình 3.3: Số ảnh của mỗi món theo tập. Bún bò Huế có nhiều ảnh train nhất (1 071 ảnh), bánh pía ít nhất (310 ảnh), chênh 3.5 lần; ba tập giữ cùng tỉ lệ giữa các món.

Mất cân bằng chỉ ở mức vừa phải và món ít ảnh nhất vẫn có hơn 300 ảnh train, nên nhóm giữ mọi món, không lấy mẫu lại và không dùng trọng số lớp, nhưng vẫn chọn mô hình theo macro-F1 để mọi món có trọng số như nhau.



Hình 3.4: Bốn ảnh train ngẫu nhiên của mỗi món. Ảnh được chụp từ nhiều góc, nhiều kiểu bày đĩa và điều kiện ánh sáng khác nhau. Nhiều món rất giống nhau, như các món nước (phở, bún bò Huế, hủ tiếu, bún riêu, bánh canh) hay các loại bánh làm từ bột gạo (bánh bèo, bánh đúc, bánh bột lọc).



Hình 3.5: Độ bão hòa và độ sáng trung bình của ảnh theo món. Trung vị độ bão hòa của các món chỉ trải từ 0.33 (cháo lòng) đến 0.52 (bánh xèo), trong khi khoảng tứ phân vị bên trong một món trung bình đã rộng 0.16, nên màu sắc tổng thể khó đủ để phân biệt 30 món.

3.5 Tiền xử lý và tăng cường dữ liệu

Validation và test không bị bỏ ảnh nào, để giữ nguyên cách chia chính thức; mọi thống kê học từ dữ liệu chỉ được fit trên train.

1. Làm sạch train: bỏ 5 ảnh có cạnh ngắn dưới 128 px, 182 ảnh trùng với validation hoặc test, 35 ảnh trùng mang nhãn khác và 144 ảnh lặp lại cùng nhãn; train còn 17 215 ảnh. Ảnh validation và test được đánh dấu nếu có bản gần trùng trong train trước khi làm sạch (123 ảnh test) hoặc có bản sao mang nhãn khác (37 ảnh test).

2. Mã hóa nhãn bằng `LabelEncoder`: 30 tên món thành số nguyên 0-29.

3. Thu nhỏ một lần và lưu lại: ResNet50 nhận ảnh 224 x 224 px, trong khi ảnh gốc có cạnh ngắn trung vị 700 px, và giải mã ảnh JPEG lớn ở mọi epoch rất chậm. Mọi ảnh được thu nhỏ để cạnh ngắn bằng 256 px (giữ tỉ lệ) và lưu vào `data/processed/` cùng cấu trúc thư mục; mọi mô hình đọc ảnh từ đây, ảnh gốc không bị thay đổi.

4. Đưa ảnh vào mạng: đổi kích thước để cạnh ngắn bằng 256 px (ảnh nhỏ hơn được phóng to), cắt phần giữa 224 x 224 px, chuẩn hóa từng kênh màu theo trung bình và độ lệch chuẩn của ImageNet. Ảnh luôn được cắt thành hình vuông nên không cần thêm viền.

5. Chuẩn hóa vector đặc trưng trước Logistic Regression: chuẩn hóa L2 với đặc trưng ResNet50 (đưa mỗi vector về độ dài 1), `StandardScaler` với đặc trưng thủ công (vì hai phần của vector có thang đo khác nhau).

Tăng cường dữ liệu. Mỗi ảnh train được biến đổi ngẫu nhiên ở mỗi epoch, để mạng thấy nhiều phiên bản khác nhau của cùng một ảnh, học những đặc điểm không đổi của món ăn thay vì học thuộc từng ảnh (Bảng 3.3). Tăng cường chỉ áp dụng cho train và chỉ khi trọng số của mạng được huấn luyện (fine-tune); validation và test luôn dùng phép biến đổi cố định để điểm số không phụ thuộc vào yếu tố ngẫu nhiên. Ở cách trích đặc trưng, mạng không được huấn luyện nên mỗi ảnh chỉ đi qua mạng một lần.

Bảng 3.3: Các phép tăng cường dữ liệu và mục tiêu.

Phép biến đổi	Tham số	Mục tiêu
Cắt khung ngẫu nhiên	224 x 224, giữ 70-100% diện tích	mô phỏng khung hình và khoảng cách chụp khác nhau; món ăn vẫn nằm trong khung
Lật ngang	xác suất 0.5	ảnh lật ngang vẫn là cùng một món
Đổi màu nhẹ	độ sáng, tương phản $\pm$20%; độ bão hòa $\pm$10%; sắc màu $\pm$0.02	mô phỏng ánh sáng khác nhau; sắc màu chỉ đổi rất ít vì màu là đặc điểm thật của món

Không lật dọc hay xoay mạnh, vì ảnh món ăn thật hiếm khi bị như vậy.



Hình 3.6: Một ảnh train của món bánh xèo và sáu phiên bản tăng cường ngẫu nhiên: món ăn và màu sắc của nó vẫn nhận ra được.

3.6 Xây dựng mô hình

Nhóm dùng ResNet50 với trọng số ImageNet của torchvision [2], một trong các mạng đề gợi ý. Mạng được coi như một hàm có sẵn: nhận ảnh 224 x 224 và trả về một vector 2 048 chiều mô tả nội dung ảnh; lớp cuối biến vector này thành xác suất của từng lớp. Ba mô hình được xây dựng (Bảng 3.4). Logistic Regression nhiều lớp là một lớp tuyến tính cộng softmax, đúng bằng lớp cuối của ResNet50, nên cả ba mô hình có cùng một kiểu đầu phân loại và chỉ khác nhau ở đặc

trưng. Mô hình được huấn luyện trên train đã làm sạch và chọn theo macro-F1 trên validation; tập test chỉ dùng một lần. Logistic Regression dùng tham số mặc định của scikit-learn.

Bảng 3.4: Ba mô hình được so sánh.

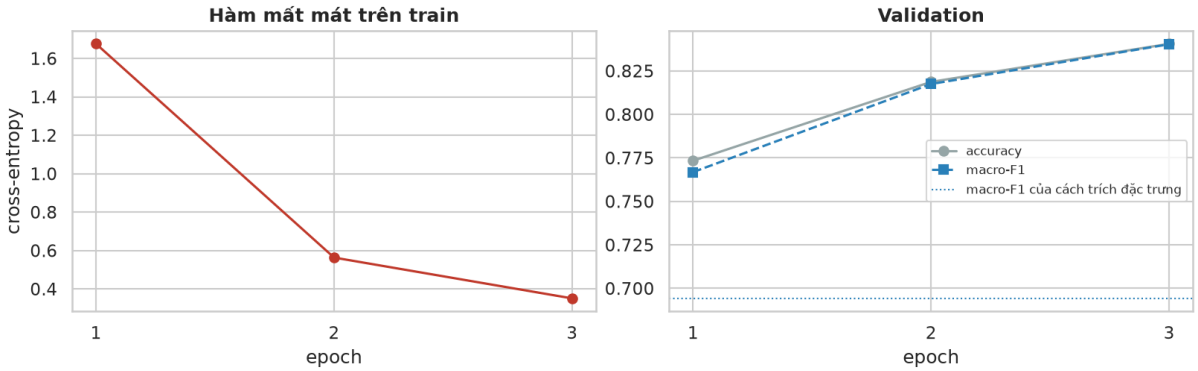
Mô hình	Đặc trưng	Phần được huấn luyện	Đầu phân loại
ResNet50 trích đặc trưng	vector 2 048 chiều của ResNet50 giữ nguyên	đầu phân loại	Logistic Regression
ResNet50 fine-tune nhẹ	ResNet50, khối cuối `layer4` học lại	`layer4` và đầu phân loại	tuyến tính 2048 → 30 + softmax
Baseline thủ công	histogram màu + SIFT (OpenCV)	đầu phân loại	Logistic Regression

3.6.1 ResNet50 làm bộ trích đặc trưng

ResNet50 bỏ lớp phân loại cuối và giữ nguyên toàn bộ trọng số; mỗi ảnh đi qua mạng một lần và trở thành một vector 2 048 chiều, rồi Logistic Regression được huấn luyện trên vector của tập train. Chỉ huấn luyện đầu phân loại đã đạt macro-F1 validation 0.694 và top-3 0.873, trong khi đoán ngẫu nhiên chỉ đạt khoảng 0.033.

3.6.2 Fine-tune nhẹ ResNet50

Bắt đầu từ cùng ResNet50, lớp cuối được thay bằng một lớp tuyến tính 30 lớp mới; mọi lớp trừ khối cuối `layer4` và lớp mới bị đóng băng (15.0 triệu trên 23.6 triệu tham số được huấn luyện). Mạng được huấn luyện 3 epoch bằng Adam với learning rate nhỏ (10^{-4}) để không phá vỡ trọng số đã học, batch 64, có tăng cường dữ liệu, và epoch có macro-F1 validation cao nhất được giữ lại.



Hình 3.7: Hàm mất mát train và kết quả validation qua các epoch. Macro-F1 validation tăng từ 0.767 lên 0.817 rồi 0.840; đường chấm là macro-F1 của cách trích đặc trưng (0.694).

Sau fine-tune, macro-F1 validation là 0.840, cao hơn cách trích đặc trưng 14.6 điểm; ngay sau epoch đầu tiên mô hình đã vượt cách trích đặc trưng. Validation vẫn đang tăng ở epoch 3, nên huấn luyện thêm có thể còn cải thiện.

3.6.3 Baseline: đặc trưng thủ công

Để biết mạng học sẵn đóng góp bao nhiêu, cùng một Logistic Regression được huấn luyện trên đặc trưng thiết kế bằng tay, tính trên ảnh 128 x 128 px:

- **Histogram màu** trong không gian HSV (OpenCV, 8 x 8 x 8 = 512 chiều): trên đĩa có những màu nào.
- **SIFT** (OpenCV): tìm các điểm nổi bật và mô tả vùng quanh mỗi điểm bằng một vector 128 chiều về hướng của các cạnh. Vì mỗi ảnh có số điểm khác nhau, nhóm dùng *túi từ thị giác*: `MiniBatchKMeans` của scikit-learn gom các vector SIFT của 2 000 ảnh train thành 256 cụm, và mỗi ảnh được mô tả bằng tỉ lệ điểm rơi vào từng cụm (256 chiều).

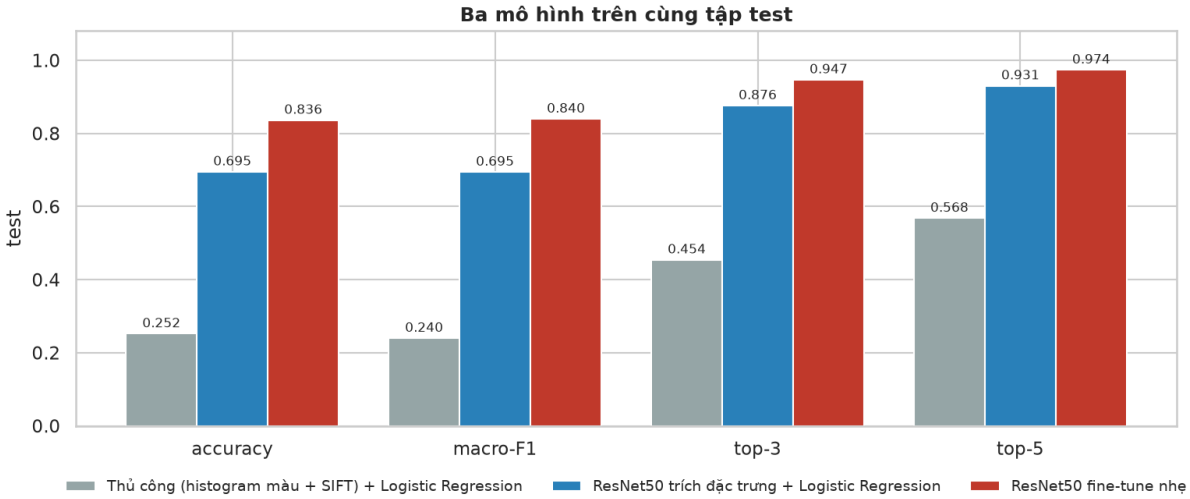
Baseline đạt macro-F1 validation 0.241, cao hơn đoán ngẫu nhiên nhưng thấp hơn ResNet50 trích đặc trưng gần 3 lần: màu sắc và hình dạng cục bộ không đủ để phân biệt các món có màu và cách bày giống nhau. Theo cách chọn mô hình, **ResNet50 fine-tune nhẹ** (macro-F1 validation 0.840) là mô hình cuối cùng.

3.7 Đánh giá trên tập test

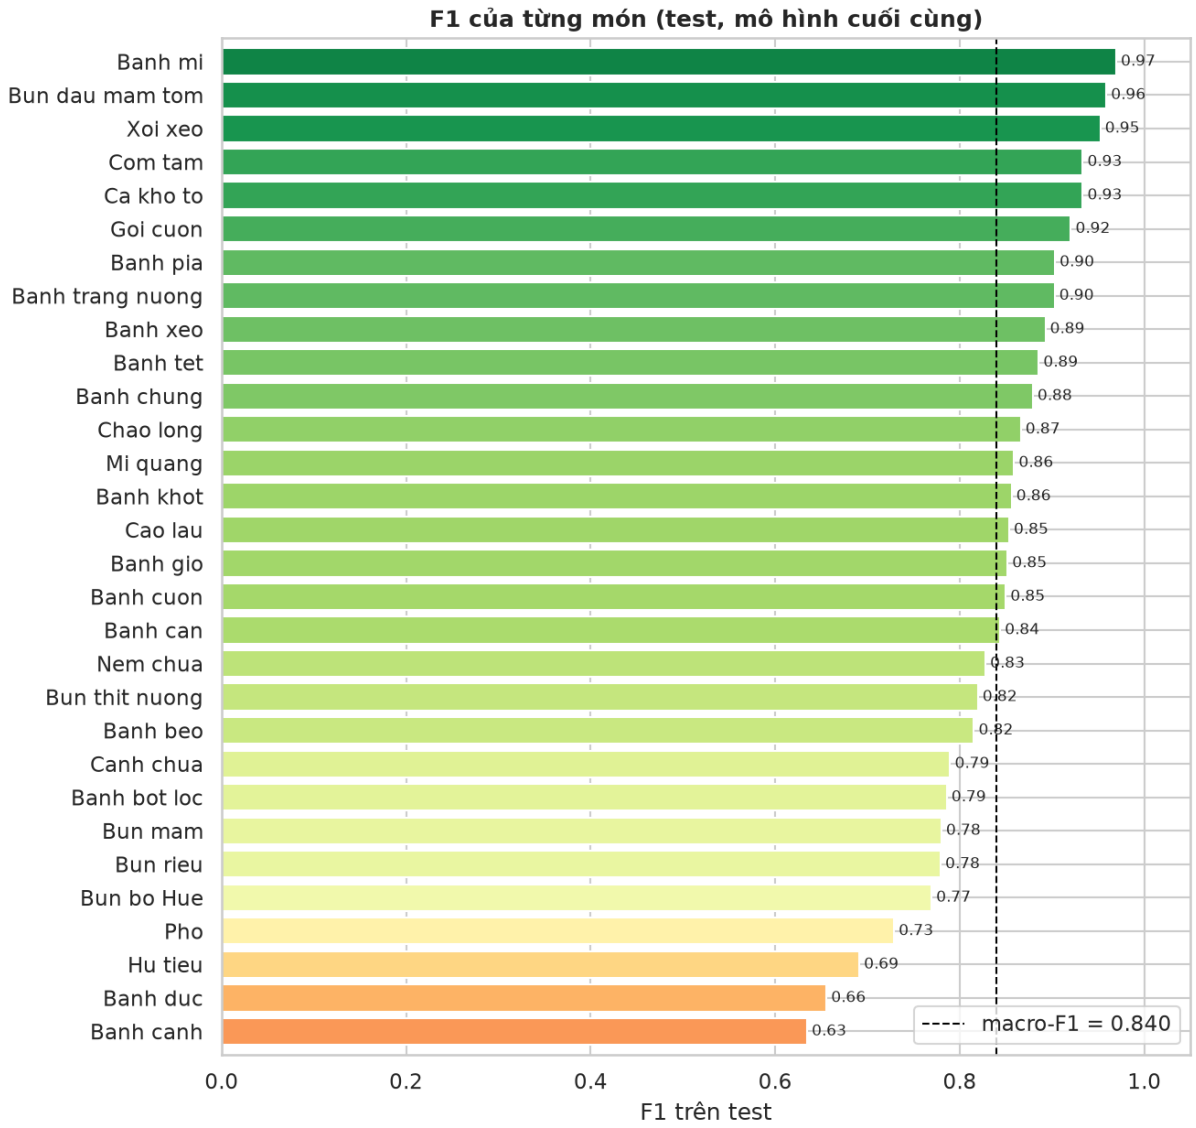
Bảng 3.5: Kết quả trên tập test (5 040 ảnh). Hàng in đậm là mô hình cuối cùng, chọn theo macro-F1 validation.

Mô hình	Đặc trưng	Accuracy	Macro-F1	Top-3	Top-5
Baseline thủ công	histogram màu + SIFT	0.2522	0.2400	0.4544	0.5683
ResNet50 trích đặc trưng	ResNet50 giữ nguyên	0.6952	0.6945	0.8762	0.9306
ResNet50 fine-tune nhẹ	**layer4 học lại**	**0.8363**	**0.8397**	**0.9470**	**0.9738**
Bài báo gốc		0.7754			0.9607

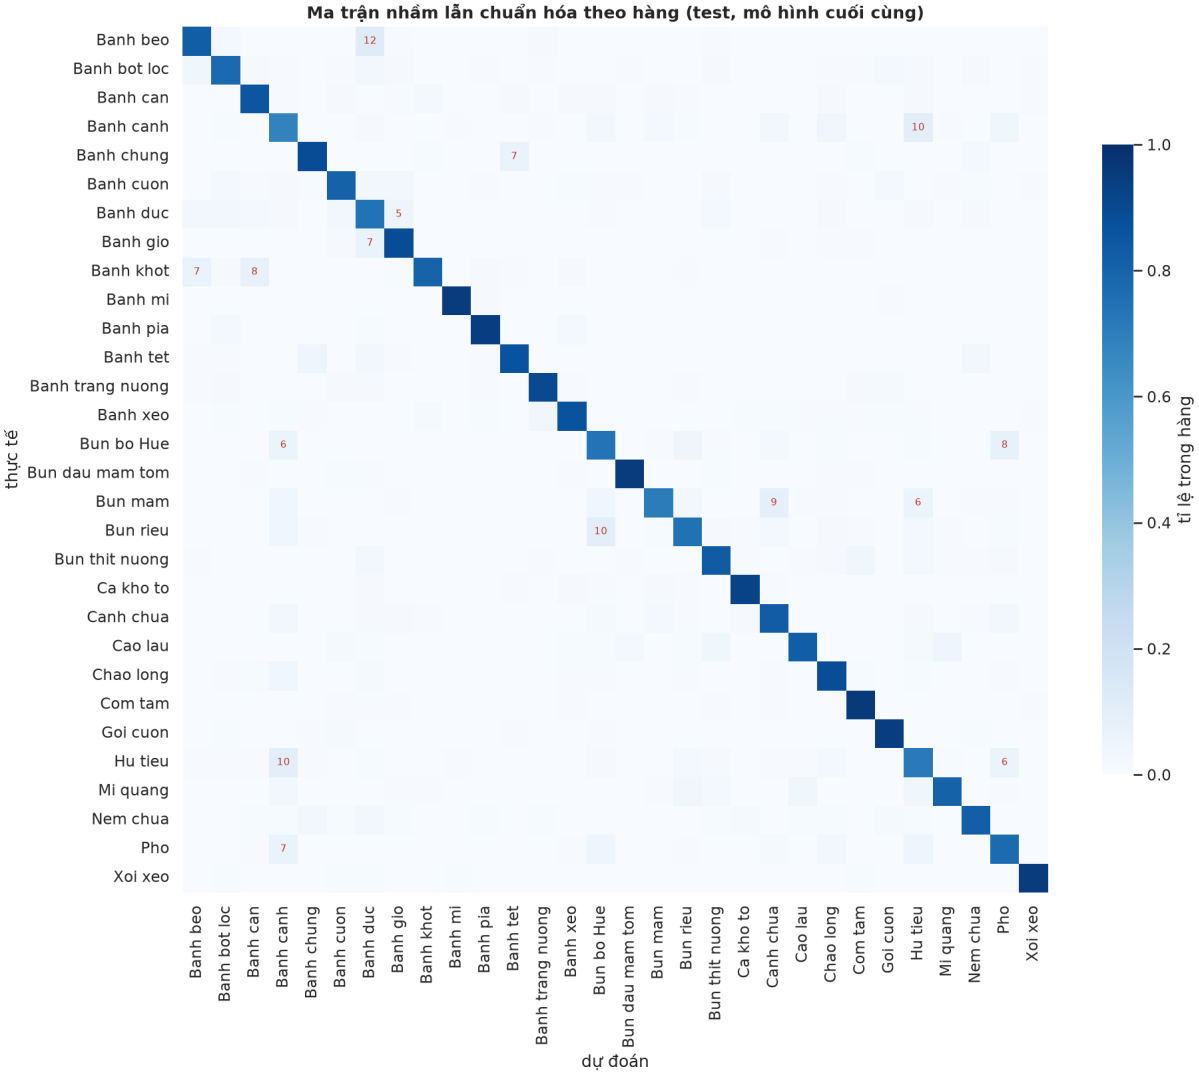
Mô hình cuối cùng đạt accuracy 0.8363 và top-5 0.9738, cao hơn bài báo gốc (0.7754 và 0.9607). Thứ tự ba mô hình trên test giống trên validation, và macro-F1 trên test gần như bằng trên validation (0.8397 so với 0.8403).



Hình 3.8: Ba mô hình trên cùng tập test, cùng một kiểu đầu phân loại. Macro-F1 tăng từ 0.240 (đặc trưng thủ công) lên 0.695 (ResNet50 trích đặc trưng, +45.5 điểm) và 0.840 (fine-tune nhẹ, thêm 14.5 điểm).



Hình 3.9: F1 của từng món trên test. F1 trải từ 0.63 (bánh canh) đến 0.97 (bánh mì); ba món khó nhất (bánh canh, bánh đúc, hủ tiếu) đều thuộc nhóm món nước hoặc bánh làm từ bột gạo.

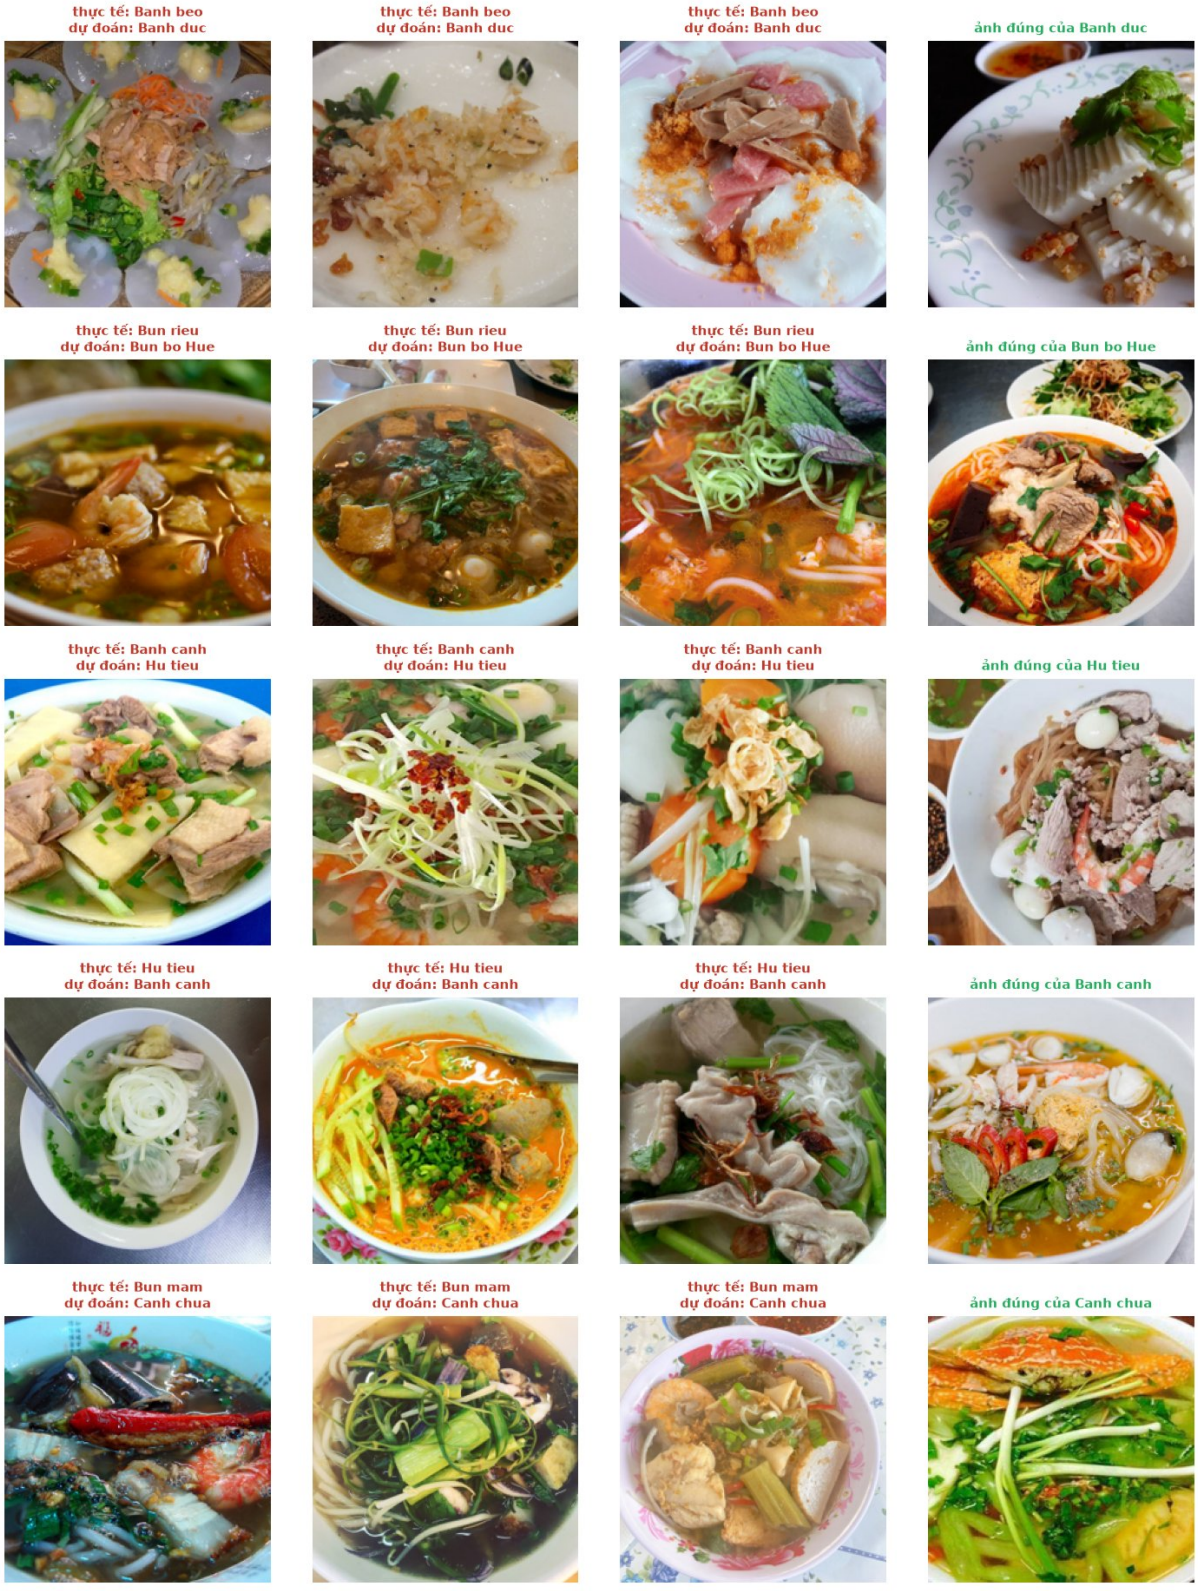


Hình 3.10: Ma trận nhầm lẫn chuẩn hóa theo hàng. Số màu đỏ là 15 ô ngoài đường chéo từ 5% trở lên, trên tổng số 870 ô: lỗi tập trung vào một số cặp món.

3.7.1 Những món nào hay bị nhầm với nhau?

Bảng 3.6: Năm cặp món bị nhầm nhiều nhất (tỉ lệ trên số ảnh test của món thực tế).

Món thực tế	Bị đoán thành	Tỉ lệ	Số ảnh	Chiều ngược lại
Bánh bèo	Bánh đúc	12.4%	16	3.0%
Bún riêu	Bún bò Huế	10.4%	24	4.6%
Bánh canh	Hủ tiếu	10.4%	20	10.2%
Hủ tiếu	Bánh canh	10.2%	20	10.4%
Bún mắm	Canh chua	9.0%	14	2.4%

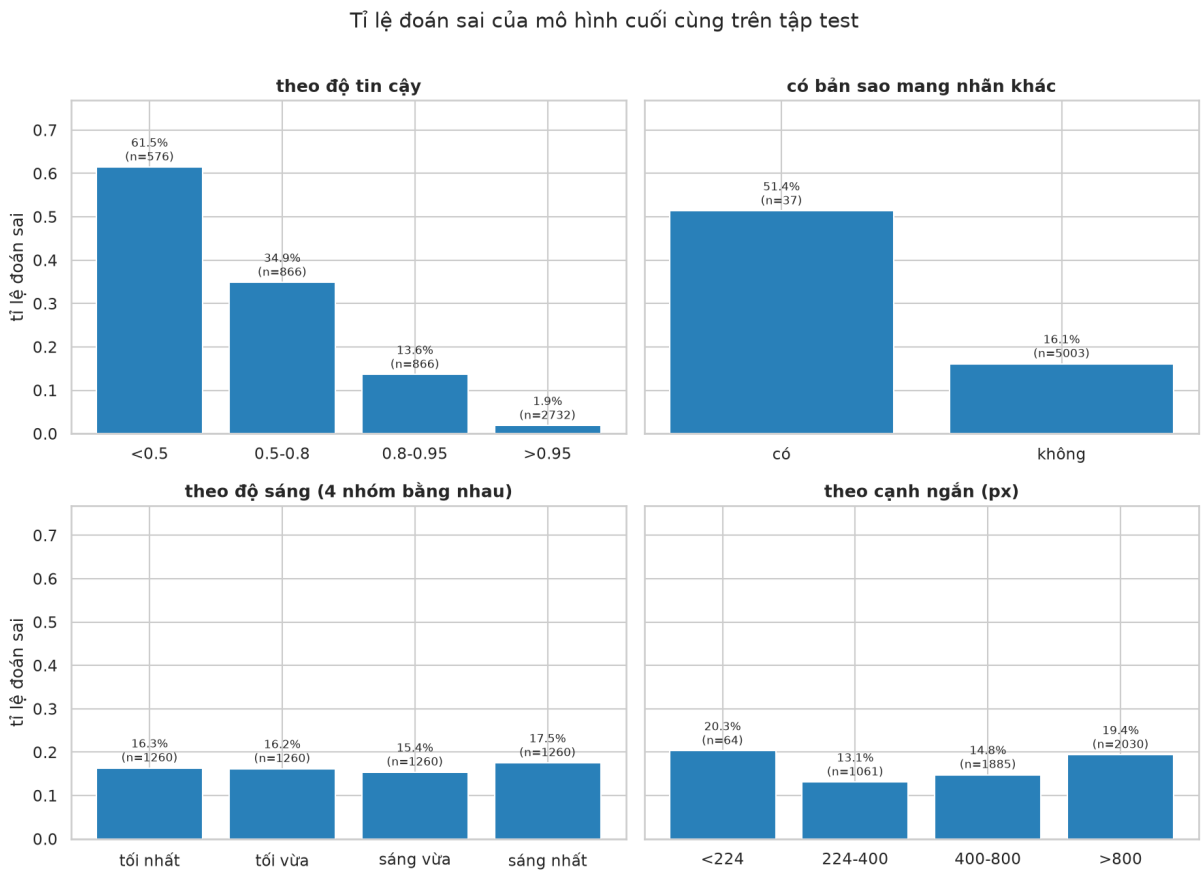


Hình 3.11: Ba lỗi của mỗi cặp nhầm nhiều nhất (đỏ) cạnh một ảnh đoán đúng của món bị đoán nhầm sang (xanh).

Năm cặp này chiếm 94 trên 825 lỗi. Mọi cặp đều là hai món cùng nhóm: bánh làm từ bột gạo hoặc món nước, đúng với những nhóm món giống nhau đã thấy khi phân tích khám phá. Bánh

canh và hủ tiếu bị nhầm theo cả hai chiều với tỉ lệ gần bằng nhau.

3.7.2 Mô hình sai ở đâu?



Hình 3.12: Tỉ lệ đoán sai trên test theo độ tin cậy của mô hình, theo việc ảnh có bản sao mang nhãn khác, theo độ sáng và theo kích thước ảnh. Tỉ lệ sai chung là 16.4%.

- **Độ tin cậy** là dấu hiệu rõ nhất: ảnh có xác suất dưới 0.5 sai 61.5% (576 ảnh), còn ảnh có xác suất trên 0.95 chỉ sai 1.9% (2 732 ảnh, hơn một nửa tập test).
- **Nhãn mâu thuẫn:** 37 ảnh test có bản sao mang nhãn khác bị đoán sai 51.4%, so với 16.1% ở các ảnh còn lại; với những ảnh này, nhãn trong dữ liệu có thể chính là chỗ sai.
- **Độ sáng và kích thước** gần như không ảnh hưởng: tỉ lệ sai từ 15.4% đến 17.5% giữa bốn nhóm độ sáng, và không có xu hướng rõ theo kích thước ảnh.
- **Số ảnh train:** hệ số tương quan Spearman giữa số ảnh train và F1 của từng món là -0.08 ($p = 0.669$). Món khó là món giống một món khác, không phải món ít ảnh.



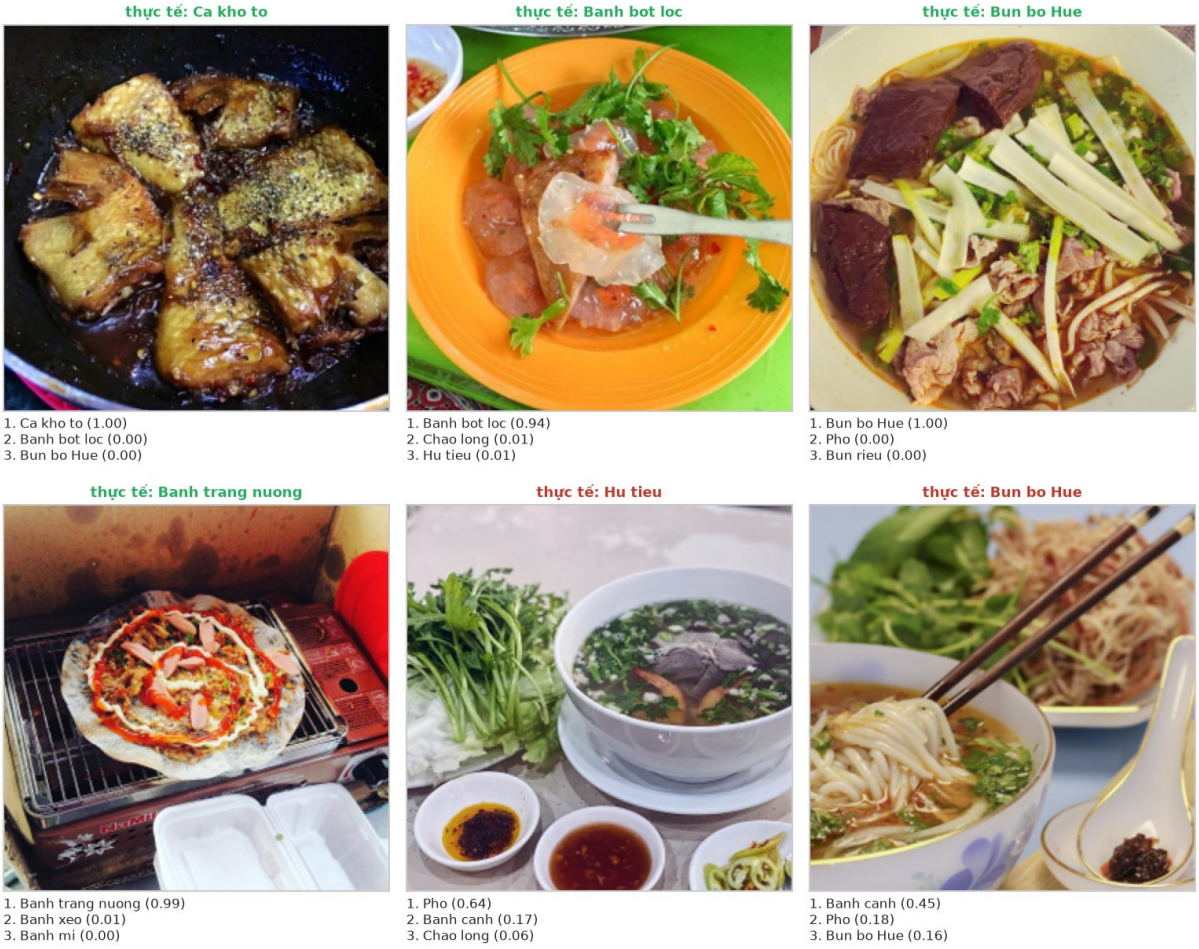
Hình 3.13: Mười sáu ảnh test bị đoán sai với độ tin cậy cao nhất (từ 0.99 trở lên); 3 ảnh mang dấu `[trùng]`, tức có bản sao mang nhãn khác. Độ tin cậy trung vị là 0.54 với ảnh đoán sai và 0.98 với ảnh đoán đúng.

Lỗi tự tin là lỗi của nhãn. Khi mô hình rất chắc chắn mà vẫn sai, nhóm xem lại chính nhãn của ảnh. Trong 16 ảnh ở Hình 3.13, ít nhất 9 ảnh khớp với món mô hình dự đoán hơn là nhãn gốc: hai ảnh gắn nhãn bánh cuốn và nem chua là gỏi cuốn, ảnh gắn nhãn canh chua là cá kho tộ, ảnh gắn nhãn bún bò Huế là phở, ảnh gắn nhãn bún riêu là bún bò Huế, ảnh gắn nhãn bánh đúc là bánh giò, ảnh gắn nhãn bánh bột lọc là bánh bèo, ảnh gắn nhãn bánh khọt là bánh căn và

ảnh gắn nhãn bánh tráng nướng là bánh cuốn. Chỉ 3 trong 16 ảnh có bản sao mang nhãn khác, nên phần lớn nhãn sai này không tìm được bằng cách tìm ảnh trùng. Nhãn sai trong tập test làm điểm test thấp hơn chất lượng thật của mô hình; nhóm không sửa nhãn để giữ nguyên tập test chính thức.

3.8 Dự đoán ảnh mới

Hàm `predict_image()` chạy toàn bộ quy trình trên một file ảnh bất kỳ: đọc ảnh, đổi sang RGB, cùng phép biến đổi kích thước và chuẩn hóa, rồi mô hình cuối cùng, và trả về 3 món có xác suất cao nhất. Khi xác suất của gợi ý đầu tiên thấp (dưới 0.5), ứng dụng nên hiện cả 3 gợi ý thay vì một câu trả lời.



Hình 3.14: Ba gợi ý của mô hình cho sáu ảnh test đọc từ file gốc, gồm bốn ảnh đoán đúng và hai ảnh đoán sai (tên màu đỏ). Món đúng nằm trong ba gợi ý ở 5 trên 6 ảnh.

3.9 Kết luận

Mô hình cuối cùng, ResNet50 với khối cuối được fine-tune nhẹ, đạt accuracy 0.8363, macro-F1 0.8397 và top-3 0.9470 trên tập test, cao hơn bài báo gốc (accuracy 0.7754). Với cùng một kiểu

đầu phân loại, đặc trưng học sẵn từ ImageNet là bước tiến lớn nhất so với đặc trưng thủ công (macro-F1 từ 0.2400 lên 0.6945), và fine-tune nhẹ khối cuối cải thiện thêm 14.5 điểm. Lỗi tập trung ở các cặp món cùng nhóm và ở các ảnh bị gán nhãn sai trong dữ liệu.

Hạn chế

- Mỗi ảnh chỉ có một nhãn, trong khi một số ảnh có nhiều món; các biến thể vùng miền của một món được gộp chung.
- Nhãn sai vẫn còn trong val và test: 37 ảnh test có bản sao mang nhãn khác, và ít nhất 9 trong 16 lỗi tự tin nhất là ảnh bị gán nhãn sai. Nhóm không sửa nhãn, nên điểm test có thể thấp hơn chất lượng thật của mô hình.
- pHash chỉ tìm được bản sao của cùng một ảnh, không tìm được hai ảnh khác nhau chụp cùng một đĩa.
- Logistic Regression dùng tham số mặc định; fine-tune chỉ chạy 3 epoch trong khi validation vẫn đang tăng.
- Chỉ một mạng pretrained (ResNet50) được thử.
- Ảnh lấy từ Internet thường được chụp đẹp, khác ảnh chụp bằng điện thoại trong quán ăn.

Hướng mở rộng

Fine-tune lâu hơn hoặc mở thêm `layer3`; thử các mạng khác như MobileNetV3 (nhẹ hơn, để chạy trên điện thoại) hoặc ViT-B/16; kiểm tra lại nhãn của các ảnh mô hình đoán sai với độ tin cậy cao và các ảnh có bản sao mang nhãn khác, rồi sửa hoặc bỏ chúng; tìm ảnh gần trùng bằng độ tương đồng của đặc trưng CNN, ngoài pHash.

Tài liệu tham khảo

[1] T.-H. Do, D.-D.-A. Nguyen, H.-Q. Dang, H.-N. Nguyen, P.-P. Pham, D.-T. Nguyen. *30VNFoods: A Dataset for Vietnamese Foods Recognition*. 2021 IEEE International Conference on Communication, Networks and Satellite (COMNETSAT), 2021. DOI: 10.1109/COMNETSAT53002.2021.9530774.

[2] K. He, X. Zhang, S. Ren, J. Sun. *Deep Residual Learning for Image Recognition*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.